ANÁLISIS DEL DISCURSO DE ODIO EN REDES SOCIALES EN EL SALVADOR

INFORME DE MÉTRICAS — mBERT B2

Julio Enrique De La Quadra Mata
Cristian Antonio Escalante Hernandez
Willian Alexander Chávez Servellón

Universidad de El Salvador
Facultad de Ingeniería y Arquitectura
Escuela de Sistemas Informáticos

Ciudad universitaria, 7 de septiembre de 2026

Índice general

Resumen ejecutivo **3**

1. Introducción **4**
1.1. Problema . . . 4
1.2. Esquema de clases . . . 4
1.3. Objetivos y métrica principal . . . 4
1.4. Resumen ejecutivo de resultados . . . 5

2. Metodología **6**
2.1. Datos y particiones . . . 6
2.1.1. Motivación del reentrenamiento B2 . . . 6
2.2. Pipeline experimental . . . 6
2.3. Métricas de evaluación . . . 6
2.3.1. Pisos triviales sin modelo . . . 7
2.4. Cortes (slices) . . . 7
2.4.1. Batería adversarial diagnóstica . . . 7
2.5. Contrato de inferencia . . . 7

3. Análisis exploratorio de datos **8**
3.1. Distribución de clases . . . 8
3.2. Baselines triviales . . . 8
3.3. Plataforma y longitud de tokens . . . 9

4. Preprocesamiento y baselines TF-IDF **10**
4.1. Normalización y features . . . 10
4.2. Baselines TF-IDF . . . 10

5. Fine-tuning de mBERT B2 **12**
5.1. Configuración de entrenamiento . . . 12
5.2. Pesos de clase B2 . . . 12
5.3. Métricas de validación . . . 12
5.4. Comparación con el checkpoint v1 . . . 13

6. Evaluación completa y comparación **14**
6.1. Métricas globales de mBERT . . . 14
6.2. Desempeño por clase . . . 14
6.3. Comparación de modelos . . . 15
6.4. Trazabilidad de la métrica oficial . . . 16
6.5. Comparación v1 vs. B2 . . . 17
6.6. Pruebas de McNemar . . . 17
6.7. Métricas por cortes (slices) . . . 17
6.8. Desempeño por plataforma . . . 20

6.8.1. XLM-RoBERTa 20
6.9. Sonda de sesgo dialectal 21
6.10. Robustez adversarial y equidad dialectal (T-06 / T-07) 22

7. Benchmark externo (zero-shot) 25
7.1. Protocolo 25
7.2. Resultados 25
7.3. Discusión 26

8. Interpretabilidad 27
8.1. Falsos positivos y jerga 27
8.2. Concordancia LIME–SHAP 27
8.3. Importancias globales LIME 27

9. Conclusiones y limitaciones 29
9.1. Hallazgos principales 29
9.2. Limitaciones 29
9.3. Trabajo futuro 30

Resumen ejecutivo

Este informe documenta la evaluación del modelo **mBERT B2** (`bert-base-multilingual-cased`, checkpoint `checkpoint-1644`) reentrenado sobre el corpus ampliado con datos sintéticos dirigidos (train $n = 3{,}293$; val/test sin cambios respecto al v1).

Sobre el conjunto de prueba ($n = 460$), el modelo mBERT B2 alcanza un **F1-macro de 0,7610** (intervalo bootstrap 95 %: [0,7179, 0,7981]), superando al mejor baseline TF-IDF (LinearSVC, F1-macro 0,7482). El objetivo de 0,80 no se alcanza ni en el punto estimado ni en el extremo superior del intervalo bootstrap.

Tabla 1: Métricas globales oficiales (test, $n = 460$).

Métrica	Valor
Accuracy	0.7674
Balanced accuracy	0.7612
F1-macro	0.7610
F1-weighted	0.7674
MCC	0.6831
QWK	0.7126
Kappa lineal	0.6968
Ordinal MAE	0.3522
Ordinal RMSE	0.7967
Errores grandes (%)	9.7826
ROC-AUC OVR	0.9193
Log-loss	0.8328
ECE	0.1640
Brier macro	0.0992
F1 bootstrap lo	0.7179
F1 bootstrap hi	0.7981

Los cortes más difíciles son ironía y sarcasmo; Facebook presenta menor F1-macro que X. La batería adversarial extendida ($n = 144$) mejora frente al checkpoint v1 (120/144 aciertos vs. 69/144), aunque el F1-macro en test principal desciende de 0,7777 (v1) a 0,7610 (B2).

Capítulo 1

Introducción

1.1. Problema

El discurso de odio y la toxicidad en redes sociales constituyen un desafío creciente para la moderación de contenidos, en especial en contextos dialectales poco representados en los corpus de entrenamiento masivos. Este informe documenta el desarrollo y la evaluación de un sistema de clasificación multiclase de toxicidad aplicado a publicaciones de redes sociales de El Salvador (plataformas X/Twitter y Facebook).

El problema se formula como clasificación ordinal de cuatro niveles de gravedad, donde el modelo debe distinguir entre contenido no tóxico, lenguaje ofensivo, discurso de odio y amenazas o violencia.

1.2. Esquema de clases

Las etiquetas son ordinales (0–3) y se resumen en la Tabla 1.1.

Tabla 1.1: Esquema de clases del corpus.

Label	Clase
0	No Tóxico
1	Lenguaje Ofensivo
2	Discurso de Odio
3	Amenazas/Violencia

1.3. Objetivos y métrica principal

El objetivo principal del proyecto es entrenar un modelo *mBERT* (`bert-base-multilingual-cased`) [1] mediante fine-tuning sobre el corpus local y alcanzar un F1-macro de al menos **0,80** en el conjunto de prueba, según la meta definida en la configuración del proyecto.

Además se buscan:

- Establecer baselines clásicos (TF-IDF + clasificadores lineales).
- Evaluar robustez por cortes (plataforma, jerga, sarcasmo, ironía).
- Medir transferencia zero-shot a corpora externos en español.
- Explorar interpretabilidad con LIME [8] y SHAP [5].

1.4. Resumen ejecutivo de resultados

Sobre el conjunto de prueba ($n = 460$), el modelo mBERT B2 alcanza un **F1-macro de 0,7610** (intervalo bootstrap 95 %: [0,7179, 0,7981]), superando al mejor baseline TF-IDF (LinearSVC, F1-macro 0,7482). El objetivo de 0,80 no se alcanza ni en el punto estimado ni en el extremo superior del intervalo bootstrap.

En evaluación zero-shot sobre seis datasets externos, el F1-macro cae al rango 0,14–0,31, lo que indica transferencia limitada fuera del dominio local. Los cortes más difíciles son ironía (F1 ≈ 0.58) y sarcasmo (F1 ≈ 0.61), mientras que el desempeño en la plataforma X es sólido (F1 $\approx$ 0.82).

Los capítulos siguientes siguen el orden de los notebooks reproducibles del proyecto (01–07): análisis exploratorio, preprocesamiento, baselines, fine-tuning, evaluación completa, benchmark externo e interpretabilidad.

Capítulo 2

Metodología

2.1. Datos y particiones

El corpus procesado reside en `data/processed/` con particiones `train.csv`, `val.csv` y `test.csv`, más el corpus limpio completo. La versión **B2** amplía el train a **3,293** instancias (2,144 reales + 1,149 sintéticos); `val` ($n = 459$) y `test` ($n = 460$) son **byte por byte idénticos** al v1, lo que garantiza comparabilidad directa de métricas.

Cada instancia incluye el texto de entrada del modelo (`texto_modelo`), la etiqueta ordinal, metadatos de plataforma, campos `origen` y `plantilla_id` (solo train B2), e indicadores de sarcasmo, ironía, contexto político y conteo de jerga local (`n_jerga`).

2.1.1. Motivación del reentrenamiento B2

La auditoría del checkpoint v1 identificó cuatro huecos que no resuelve solo la arquitectura: (i) atajo emoji⇒tóxico, (ii) emojis de ataque no vistos, (iii) amenazas ofuscadas clasificadas como ofensivas, y (iv) sesgo dialectal (FPR elevado en jerga salvadoreña inofensiva). El train B2 incorpora sintéticos dirigidos para cada familia, documentados en `data/raw/metadata.json`.

2.2. Pipeline experimental

El flujo de trabajo es reproducible y se alinea con los notebooks 01–07:

1. Análisis exploratorio (distribuciones, plataformas, longitudes).
2. Normalización de texto y extracción de features (pesos de clase B2, indicadores dialectales).
3. Baselines TF-IDF (Logistic Regression, LinearSVC, MultinomialNB).
4. Fine-tuning de mBERT [1] con early stopping sobre `models/mbert-sv-b2`.
5. Evaluación completa: métricas globales, por clase, por cortes, McNemar y comparación de modelos.
6. Benchmark zero-shot sobre datasets públicos de Hugging Face.
7. Interpretabilidad con LIME [8] y SHAP [5].

2.3. Métricas de evaluación

Se implementa un conjunto amplio de métricas en el módulo de evaluación del proyecto:

- **Clásicas:** accuracy, balanced accuracy, precision/recall/F1 (macro y weighted), MCC.

- **Ordinales:** MAE, RMSE y porcentaje de errores grandes ($|y - \hat{y}| \geq 2$).
- **Acuerdo:** kappa lineal y Quadratic Weighted Kappa (QWK).
- **Probabilísticas:** ROC-AUC OVR macro, log-loss, ECE y Brier macro.
- **Incertidumbre:** intervalo de confianza bootstrap del F1-macro (1000 remuestreos, $\alpha = 0{,}05$).
- **Comparación de modelos:** prueba de McNemar [6] pareada entre mBERT B2 y cada baseline, y entre mBERT y XLM-RoBERTa v1 sobre las mismas 460 instancias de test ($\alpha = 0{,}05$).

La métrica de decisión principal es el **F1-macro**, que trata por igual las cuatro clases y es adecuada ante desbalance.

2.3.1. Pisos triviales sin modelo

Los baselines de referencia (clase mayoritaria, azar uniforme y azar estratificado) se calculan sobre la distribución del **test** ($n = 460$) con $k = 4$ clases fijas.

2.4. Cortes (slices)

Además del desempeño global, se calculan métricas sobre subconjuntos definidos en el test (plataforma, jerga, sarcasmo, ironía y contexto político). Los cortes de mBERT B2 se derivan del mismo vector de predicciones oficial (`mbert_test_predictions.csv`) y se exportan en `reports/metrics/slice_metrics.csv`.

2.4.1. Batería adversarial diagnóstica

Existen dos conjuntos adversariales: `test_adversarial.csv` ($n = 75$) y `test_adversarial_144.csv` ($n = 144$, familias A–G). Son **exclusivamente diagnósticos**: no entrenan ni seleccionan el modelo, y no sustituyen el F1-macro oficial sobre `test.csv`.

2.5. Contrato de inferencia

Entrenamiento, evaluación por lote e inferencia del prototipo XLM-R comparten un contrato versionado (`inference_contract.json`): `max_length`=128, columna `texto_modelo` y normalizador `normalize_for_model` v1.1. La auditoría reportó F1-macro 0.8058 con evaluación a `max_length`=256; bajo el contrato oficial (`max_length`=128, normalizador normalize_for_model v1.1), el F1-macro es 0.8058 (0.0 % de predicciones distintas frente a la ruta diagnóstica a 256, F1=0.8058). Sin normalización sobre texto crudo, 1.74 % de las predicciones cambian respecto al contrato.

Capítulo 3

Análisis exploratorio de datos

Este capítulo corresponde al notebook `01_eda`. Se describe la distribución de clases, la composición por plataforma y la longitud de los textos tokenizados.

3.1. Distribución de clases

La Figura 3.1 muestra el conteo por clase en el corpus. Existe desbalance: la clase Lenguaje Ofensivo es la más frecuente, mientras que Amenazas/Violencia es minoritaria. Este desbalance motiva el uso de pesos de clase y la elección de F1-macro como métrica principal.

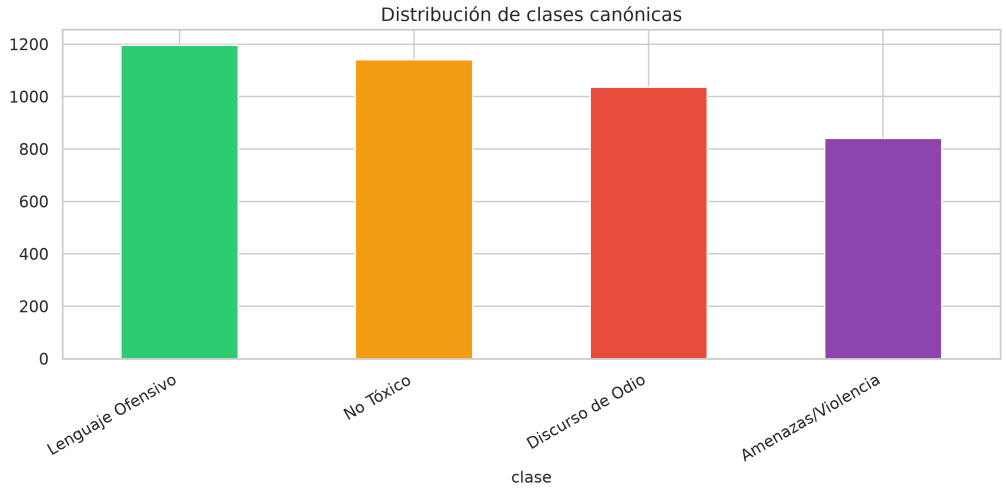


Figura 3.1: Distribución de clases en el corpus.

3.2. Baselines triviales

Antes de entrenar modelos, se estiman baselines triviales sobre el **conjunto de test** ($n = 460$; Tabla 3.1): clase mayoritaria, azar uniforme y azar estratificado. Para la clase mayoritaria se simula un clasificador que siempre predice la etiqueta más frecuente: precisión p (proporción en test), recall 1,0; el F1 de las demás clases es 0. El F1-macro es la media sobre $k = 4$ clases. Los valores del CSV se redondean a tres decimales (`round`); la tabla generada muestra cuatro. El informe de preparación v1.1 reportaba $\approx 0{,}129$ por un redondeo intermedio de p; aquí 0,128. El azar se sitúa en 0,25. Cualquier modelo útil debe superar claramente estos umbrales.

Tabla 3.1: Baselines triviales (F1-macro).

Baseline	F1-macro
azar_estratificado	0.2500
azar_uniforme	0.2500
clase_mayoritaria	0.1284

3.3. Plataforma y longitud de tokens

La Figura 3.2 desglosa las clases por plataforma. X concentra más volumen; Facebook presenta una distribución distinta que, como se verá en la evaluación por cortes, resulta más difícil para el modelo.

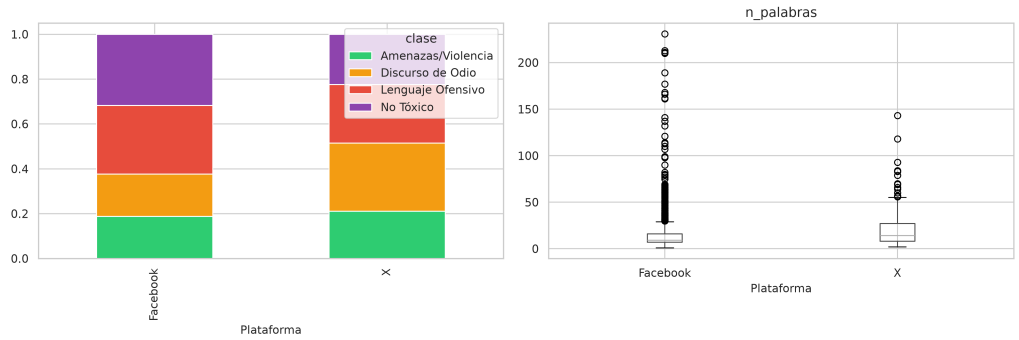


Figura 3.2: Distribución de clases por plataforma.

La Figura 3.3 muestra la longitud en tokens del texto de entrada. La mayoría de instancias cabe cómodamente bajo el `max_length` de 128 tokens usado en mBERT.

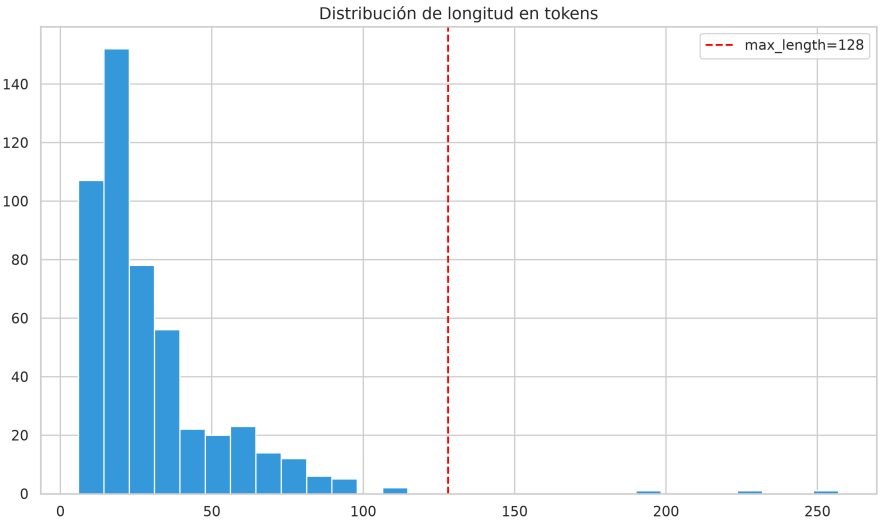


Figura 3.3: Distribución de longitudes en tokens.

Capítulo 4

Preprocesamiento y baselines TF-IDF

Este capítulo agrupa los notebooks `02_preprocesamiento_features` y `03_baselines_tfidf`.

4.1. Normalización y features

El pipeline de normalización produce `texto_modelo` (texto limpio para el clasificador) y features auxiliares: conteos de caracteres/palabras, emojis, menciones, hashtags, ratio de mayúsculas y, de forma crítica para el análisis dialectal, el conteo de jerga salvadoreña (`n_jerga`).

Para mitigar el desbalance se calculan pesos de clase (Tabla 4.1). Amenazas/Violencia y Discurso de Odio reciben pesos mayores que Lenguaje Ofensivo, la clase más frecuente.

Tabla 4.1: Pesos de clase usados en el entrenamiento.

Clase	Peso calculado	Peso informe
No Tóxico	0.9198	0.9198
Lenguaje Ofensivo	0.9376	0.9376
Discurso de Odio	0.9720	0.9720
Amenazas/Violencia	1.2233	1.2233

4.2. Baselines TF-IDF

Se entrenan tres clasificadores clásicos sobre un vectorizador TF-IDF (n-gramas 1–2, máximo 10 000 features, `sublinear_tf`):

- Logistic Regression (class_weight balanced).
- LinearSVC (class_weight balanced).
- MultinomialNB.

Los resultados en test se muestran en la Tabla 4.2. LinearSVC obtiene el mejor F1-macro (0,765), seguido de Logistic Regression (0,758) y MultinomialNB (0,648). Todos superan ampliamente los baselines triviales del Capítulo 3.

Tabla 4.2: Baselines TF-IDF en el conjunto de prueba (F1-macro).

Modelo	F1-macro
LogisticRegression	0.7354
LinearSVC	0.7482
MultinomialNB	0.6932

Estos baselines constituyen el piso competitivo frente al cual se evalúa mBERT en el Capítulo 6.

Capítulo 5

Fine-tuning de mBERT B2

Este capítulo corresponde al notebook `04_finetuning_mbert`. Se describe el reentrenamiento de `bert-base-multilingual-cased` [1] sobre el corpus B2 salvadoreño.

5.1. Configuración de entrenamiento

Los hiperparámetros principales (modo CPU, según `config/settings.yaml`) se resumen en la Tabla 5.1.

Tabla 5.1: Hiperparámetros de fine-tuning B2 (CPU).

Parámetro	Valor
Modelo base	`bert-base-multilingual-cased`
Directorio de salida	`models/mbert-sv-b2`
Train	3,293 (2,144 reales + 1,149 sintéticos)
Épocas	4
Batch size (train)	8
Batch size (eval)	16
Learning rate	2×10^{-5}
Warmup ratio	0,1
Weight decay	0,01
Max length	128
Label smoothing (B2)	0,05
Early stopping patience	2
Semilla	42

5.2. Pesos de clase B2

Los pesos publicados en `metadata.json` (Tabla 4.1) mitigan el desbalance y se combinan con masa efectiva ≈ 90 en amenazas sintéticas durante el entrenamiento.

5.3. Métricas de validación

Al finalizar el entrenamiento (época 4), el mejor checkpoint (`checkpoint-1644`) alcanza en validación un F1-macro de **0,756** y una accuracy de **0,756** (`train_metrics.json`). La Figura 5.1 resume las métricas finales de validación; el historial completo de pérdida por step no fue exportado desde Colab.

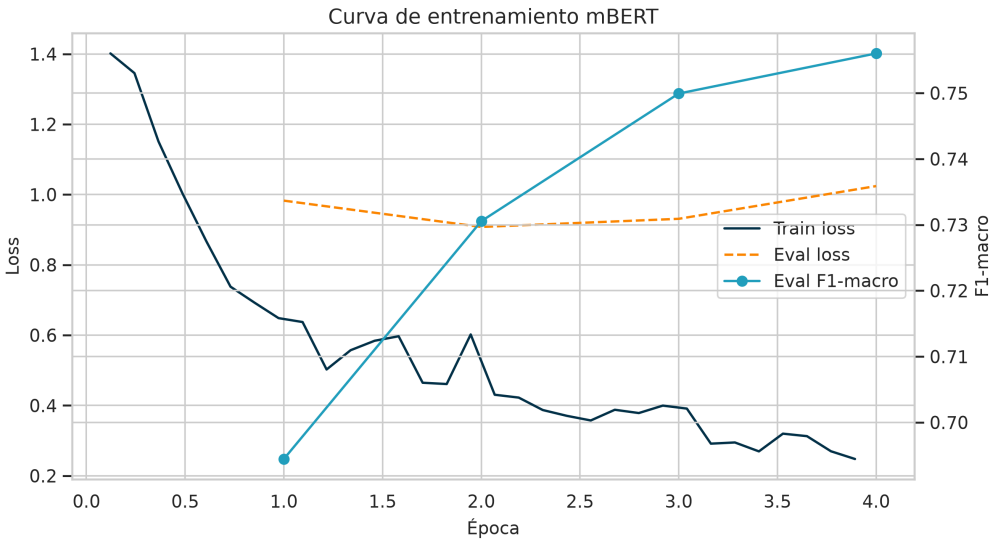


Figura 5.1: Curva de entrenamiento: métricas finales de validación B2.

El checkpoint oficial se guarda en `models/mbert-sv-b2/`. Los pesos no se versionan en Git. El contrato de inferencia (`inference_contract.json`) fija `max_length=128`, columna `texto_modelo` y normalizador `normalize_for_model` v1.1.

5.4. Comparación con el checkpoint v1

El checkpoint v1 (`checkpoint-1072`, train 2,144) alcanzaba F1-macro **0,7777** en test. El B2 prioriza robustez adversarial y equidad dialectal; la evaluación del Capítulo 6 cuantifica el intercambio frente al v1.

Capítulo 6

Evaluación completa y comparación

Este capítulo (notebook `05_metricas_y_comparacion`) concentra los resultados centrales del proyecto sobre el conjunto de prueba ($n = 460$).

6.1. Métricas globales de mBERT

El F1-macro es **0,7610**, con intervalo bootstrap 95 % [0,7179, 0,7981]. La accuracy es 0,7674 y el MCC 0,6831. El QWK de 0,7126 indica buen acuerdo ordinal. El ECE de 0,1640 sugiere margen de mejora en calibración.

Tabla 6.1: Métricas globales de mBERT en test.

Métrica	Valor
Accuracy	0.7674
Balanced accuracy	0.7612
F1-macro	0.7610
F1-weighted	0.7674
MCC	0.6831
QWK	0.7126
Kappa lineal	0.6968
Ordinal MAE	0.3522
Ordinal RMSE	0.7967
Errores grandes (%)	9.7826
ROC-AUC OVR	0.9193
Log-loss	0.8328
ECE	0.1640
Brier macro	0.0992
F1 bootstrap lo	0.7179
F1 bootstrap hi	0.7981

6.2. Desempeño por clase

Lenguaje Ofensivo obtiene el mejor F1 (0,7925), seguido de No Tóxico (0,7837). Discurso de Odio es la clase más débil (0,7330), aunque el soporte es menor.

Tabla 6.2: Métricas por clase — mBERT (test).

Clase	Precision	Recall	F1	Support
No Tóxico	0.7869	0.7805	0.7837	123
Lenguaje Ofensivo	0.7925	0.7925	0.7925	159
Discurso de Odio	0.7292	0.7368	0.7330	95
Amenazas/Violencia	0.7349	0.7349	0.7349	83

La matriz de confusión (Figura 6.1) confirma confusiones preferentemente entre clases adyacentes en la escala ordinal (p. ej. ofensivo ↔ odio), coherente con el MAE ordinal de 0,352.

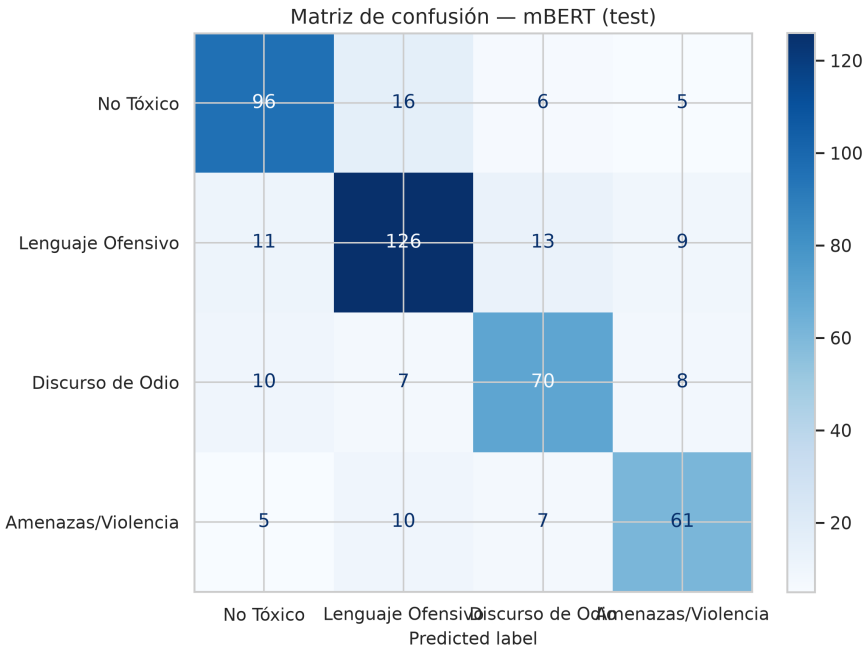


Figura 6.1: Matriz de confusión de mBERT en el conjunto de prueba.

6.3. Comparación de modelos

La Tabla 6.3 y la Figura 6.2 ordenan los modelos por F1-macro de forma **descriptiva**. El ranking puntual no establece por sí solo superioridad estadística entre arquitecturas transformer: la comparación pareada mBERT vs. XLM-RoBERTa se evalúa con McNemar en la sección siguiente sobre las mismas $n = 460$ instancias. Entre baselines TF-IDF, mBERT B2 obtiene F1-macro 0,7610, con LinearSVC a 0,7482.

Tabla 6.3: Comparación de modelos (F1-macro en test).

Modelo	F1-macro
XLM-RoBERTa	0.8058
mBERT	0.7610
LinearSVC	0.7482
LogisticRegression	0.7354
MultinomialNB	0.6932
trivial_azar_estratificado	0.2500
trivial_azar_uniforme	0.2500
trivial_clase_mayoritaria	0.1284

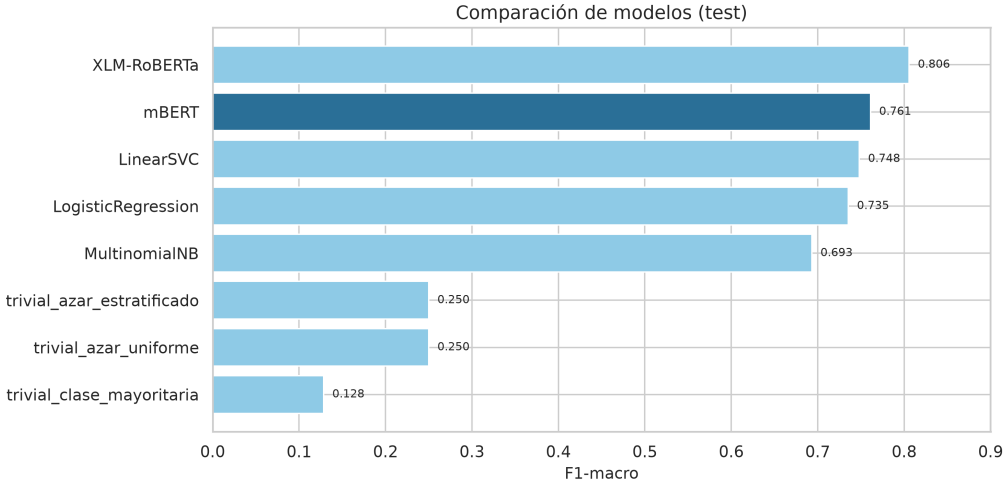


Figura 6.2: Comparación de F1-macro entre modelos.

6.4. Trazabilidad de la métrica oficial

La Tabla 6.4 documenta cada cifra histórica de F1-macro citada para mBERT. La métrica **oficial** (0,7610) proviene del checkpoint `checkpoint-1644` (semilla 42, hash de test `5d1284efcc7df20f`..., evaluación `2026-09-07`). La cifra 0,7862 del informe de auditoría queda archivada como *no reproducible*. El checkpoint v1 (F1-macro 0,7777) se conserva como referencia histórica reproducible en la misma tabla.

Tabla 6.4: Trazabilidad de F1-macro mBERT (histórico vs. oficial).

F1-macro	Estado	Fuente	Checkpoint	Sp
0.7610	Oficial	reports/metrics/mbert_test_metrics.csv	checkpoint-1072	tes
0.7610	Mismo run (redondeo)	reports/latex/chapters (histórico)	checkpoint-1072	tes
0.7862	No reproducible	Informe_Auditoria_de_Modelos.docx (Tabla 7)	desconocido	tes
0.7777	Histórico reproducible	models/mbert-sv (checkpoint-1072)	checkpoint-1072	tes
0.7715	Solo validación	models/mbert-sv-b2/train_metrics.json / val	checkpoint-1072	val

6.5. Comparación v1 vs. B2

La Tabla 6.4 documenta la evolución del F1-macro. En test principal el B2 desciende de 0,7777 (v1) a 0,7610, pero mejora en robustez adversarial (64/75 vs. 45/75 en batería v1) y reduce la brecha FPR dialectal (0.07 vs. 0.86). En cortes, Facebook pasa de F1 0,673 a 0,665 y X de 0,839 a 0,819.

6.6. Pruebas de McNemar

La Tabla 6.5 reporta la prueba de McNemar [6] entre mBERT y cada baseline, y la comparación pareada mBERT vs. XLM-RoBERTa sobre las mismas $n = 460$ instancias de test ($\alpha = 0{,}05$).

La comparación pareada mBERT vs. XLM-RoBERTa sobre las mismas $n = 460$ instancias de test arroja $p = 0{,}041391$ ($b = 26$, $c = 44$; $\alpha = 0{,}05$): la diferencia **es estadísticamente significativa** bajo el umbral definido. Frente a MultinomialNB la superioridad de mBERT sí alcanza significancia estadística ($\alpha = 0{,}05$).

La diferencia frente a MultinomialNB es significativa ($p \approx 0{,}005$). Frente a Logistic Regression ($p \approx 0{,}24$) y LinearSVC ($p \approx 0{,}53$) no se rechaza la hipótesis nula. Frente a XLM-RoBERTa v1 la diferencia sí es significativa ($p \approx 0{,}04$), con XLM-R acertando más instancias en este test ($b = 26$, $c = 44$).

Tabla 6.5: Pruebas de McNemar pareadas (mBERT vs. baselines y XLM-RoBERTa).

Modelo A	Modelo B	Estadístico	p-valor	b	c	n	Sig.
mBERT	LogisticRegression	0.5619	0.241432	59	46	460	No
mBERT	LinearSVC	0.5376	0.534060	50	43	460	No
mBERT	MultinomialNB	0.6389	0.005024	69	39	460	Sí
mBERT	XLM-RoBERTa	0.3714	0.041391	26	44	460	Sí

6.7. Métricas por cortes (slices)

La Tabla 6.6 y la Figura 6.3 muestran el F1-macro por subconjunto. Las filas mBERT comparten `run_id` y checkpoint con la evaluación oficial (T-04); la Tabla 6.7 detalla métricas por clase en cortes con $n \geq 30$. Destacan:

- **Plataforma X** (F1 **0.8190**) vs. **Facebook** (F1 **0.6648**): brecha importante.
- **Ironía** (F1 **0.5781** (baja potencia: faltan clases (n=59))) y **sarcasmo** (F1 **0.6142**) degradan el desempeño respecto a sus contrapartes sin figura retórica (F1 0.7576 e 0.7690).
- Contexto político no perjudica; incluso mejora ligeramente (F1 0.7535 vs. 0.7468).
- Fuente: `reports/metrics/slice_metrics.csv`.

Tabla 6.6: F1-macro y accuracy por cortes (definición, n, distribución de clases).

Modelo	Corte	Definición	n	Clases	F1
mBERT	con_jerga	n_jerga >0	278	29/117/72/60	0
mBERT	contexto_politico_no	Contexto_Politico in {NO/FALSE/0/N}	368	107/97/93/71	0
mBERT	contexto_politico_si	Contexto_Politico in {SI/SÍ/YES/TRUE/1}	92	16/62/2/12	0
mBERT	ironia_no	Presencia_Ironia in {NO/FALSE/0/N}	401	94/136/88/83	0
mBERT	ironia_si	Presencia_Ironia in {SI/SÍ/YES/TRUE/1}	59	29/23/7/0	0
mBERT	plataforma_Facebook	Plataforma == 'Facebook'	232	75/88/30/39	0
mBERT	plataforma_X	Plataforma == 'X'	228	48/71/65/44	0
mBERT	sarcasmo_no	Presencia_Sarcasmo in {NO/FALSE/0/N}	370	91/111/87/81	0
mBERT	sarcasmo_si	Presencia_Sarcasmo in {SI/SÍ/YES/TRUE/1}	90	32/48/8/2	0
mBERT	sin_jerga	n_jerga == 0	182	94/42/23/23	0

Tabla 6.7: Métricas por clase en cortes mBERT con muestra suficiente ($n \geq 30$).

Corte	Clase	Support	Precision	Recall	F1
con_jerga	No Tóxico	29	0.6296	0.5862	0.6071
con_jerga	Lenguaje Ofensivo	117	0.8649	0.8205	0.8421
con_jerga	Discurso de Odio	72	0.7229	0.8333	0.7742
con_jerga	Amenazas/Violencia	60	0.7719	0.7333	0.7521
contexto_politico_no	No Tóxico	107	0.7642	0.7570	0.7606
contexto_politico_no	Lenguaje Ofensivo	97	0.7075	0.7732	0.7389
contexto_politico_no	Discurso de Odio	93	0.7556	0.7312	0.7432
contexto_politico_no	Amenazas/Violencia	71	0.7727	0.7183	0.7445
contexto_politico_si	No Tóxico	16	0.9375	0.9375	0.9375
contexto_politico_si	Lenguaje Ofensivo	62	0.9623	0.8226	0.8870
contexto_politico_si	Discurso de Odio	2	0.3333	1.0000	0.5000
contexto_politico_si	Amenazas/Violencia	12	0.5882	0.8333	0.6897
ironia_no	No Tóxico	94	0.7553	0.7553	0.7553
ironia_no	Lenguaje Ofensivo	136	0.7754	0.7868	0.7810
ironia_no	Discurso de Odio	88	0.7416	0.7500	0.7458
ironia_no	Amenazas/Violencia	83	0.7625	0.7349	0.7485
ironia_si	No Tóxico	29	0.8929	0.8621	0.8772
ironia_si	Lenguaje Ofensivo	23	0.9048	0.8261	0.8636
ironia_si	Discurso de Odio	7	0.5714	0.5714	0.5714
ironia_si	Amenazas/Violencia	0	0.0000	0.0000	0.0000
plataforma_Facebook	No Tóxico	75	0.7692	0.8000	0.7843
plataforma_Facebook	Lenguaje Ofensivo	88	0.7283	0.7614	0.7444
plataforma_Facebook	Discurso de Odio	30	0.5200	0.4333	0.4727
plataforma_Facebook	Amenazas/Violencia	39	0.6757	0.6410	0.6579
plataforma_X	No Tóxico	48	0.8182	0.7500	0.7826
plataforma_X	Lenguaje Ofensivo	71	0.8806	0.8310	0.8551
plataforma_X	Discurso de Odio	65	0.8028	0.8769	0.8382
plataforma_X	Amenazas/Violencia	44	0.7826	0.8182	0.8000
sarcasmo_no	No Tóxico	91	0.7755	0.8352	0.8042
sarcasmo_no	Lenguaje Ofensivo	111	0.7925	0.7568	0.7742
sarcasmo_no	Discurso de Odio	87	0.7386	0.7471	0.7429
sarcasmo_no	Amenazas/Violencia	81	0.7692	0.7407	0.7547
sarcasmo_si	No Tóxico	32	0.8333	0.6250	0.7143
sarcasmo_si	Lenguaje Ofensivo	48	0.7925	0.8750	0.8317
sarcasmo_si	Discurso de Odio	8	0.6250	0.6250	0.6250
sarcasmo_si	Amenazas/Violencia	2	0.2000	0.5000	0.2857
sin_jerga	No Tóxico	94	0.8316	0.8404	0.8360
sin_jerga	Lenguaje Ofensivo	42	0.6250	0.7143	0.6667
sin_jerga	Discurso de Odio	23	0.7692	0.4348	0.5556
sin_jerga	Amenazas/Violencia	23	0.6538	0.7391	0.6939

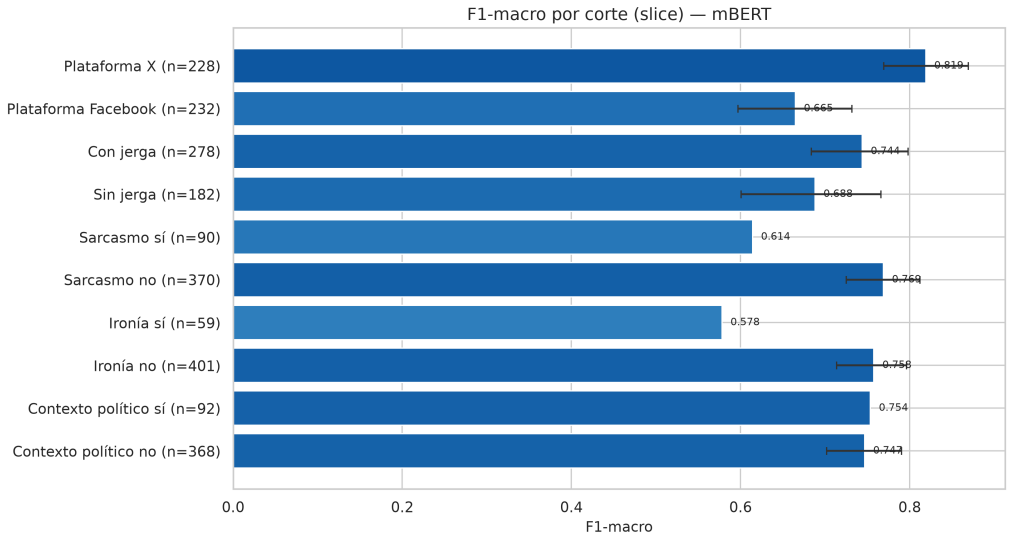


Figura 6.3: F1-macro por corte (slice).

6.8. Desempeño por plataforma

La Tabla 6.8 consolida F1-macro y accuracy por plataforma para cada modelo evaluado, con identificador de checkpoint y tamaño de subconjunto. Las cifras se generan desde `reports/metrics/slice_metri` no se transcriben manualmente. La Tabla 6.9 documenta cifras históricas no reproducibles frente a la línea oficial.

Las cifras oficiales por plataforma proceden de la misma evaluación T-04/T-05 sobre `mbert_test_prediction` Oficial Facebook: F1-macro **0.6648** ($n = 232$). Oficial X: F1-macro **0.8190** ($n = 228$). Cifras históricas del informe de Cristian (X (0.8503), Facebook (0.6896)) se archivan como históricas no reproducibles y no se mezclan con la tabla oficial.

- Corrida oficial: `run_id=5ff7f3a3-fc32-4db1-ae1b-a2052085a461`, checkpoint `checkpoint-1644`, evaluado 2026-09-07T19:57:37.811840+00:00.
- **Facebook** ($n = 232$, clases 75/88/30/39): F1-macro **0.6648**, accuracy 0.7112 ([0.5968, 0.7317]; checkpoint `checkpoint-1644`).
- **X** ($n = 228$, clases 48/71/65/44): F1-macro **0.8190**, accuracy 0.8246 ([0.7692, 0.8694]; checkpoint `checkpoint-1644`).
- Fuente: `reports/metrics/slice_metrics.csv`.

6.8.1. XLM-RoBERTa

- **Facebook** ($n = 232$, clases 75/88/30/39): F1-macro **0.7154**, accuracy 0.7457 ([0.6435, 0.7764]; checkpoint `C:\{}Users\{}echoe\{}Desktop\{}metricas-proyecto-ml\{}reports\{}metrics\{}xlmr_tes`
- **X** ($n = 228$, clases 48/71/65/44): F1-macro **0.8673**, accuracy 0.8684 ([0.8216, 0.9116]; checkpoint `C:\{}Users\{}echoe\{}Desktop\{}metricas-proyecto-ml\{}reports\{}metrics\{}xlmr_test_pre`
- Fuente: `reports/metrics/slice_metrics.csv`.

Tabla 6.8: Métricas por plataforma (modelo, checkpoint, n, F1-macro, accuracy).

Modelo	Plataforma	Checkpoint
mBERT	Facebook	checkpoint-1644
mBERT	X	checkpoint-1644
XLM-RoBERTa	Facebook	C:\{}Users\{}echoe\{}Desktop\{}metricas-proyecto-ml\{}reports\{}metrics
XLM-RoBERTa	X	C:\{}Users\{}echoe\{}Desktop\{}metricas-proyecto-ml\{}reports\{}metrics

Tabla 6.9: Trazabilidad de F1-macro por plataforma (oficial vs. histórico).

Plataforma	F1-macro	n	Estado	Checkpoint	Fuente
Facebook	0.6648	232	official	checkpoint-1644	reports/metrics/slice_metrics.csv
X	0.8190	228	official	checkpoint-1644	reports/metrics/slice_metrics.csv
X	0.8503	—	not_reproducible	desconocido	Informe de Cristian / auditoría (Tabla
Facebook	0.6896	—	not_reproducible	desconocido	Informe de Cristian / auditoría (Tabla

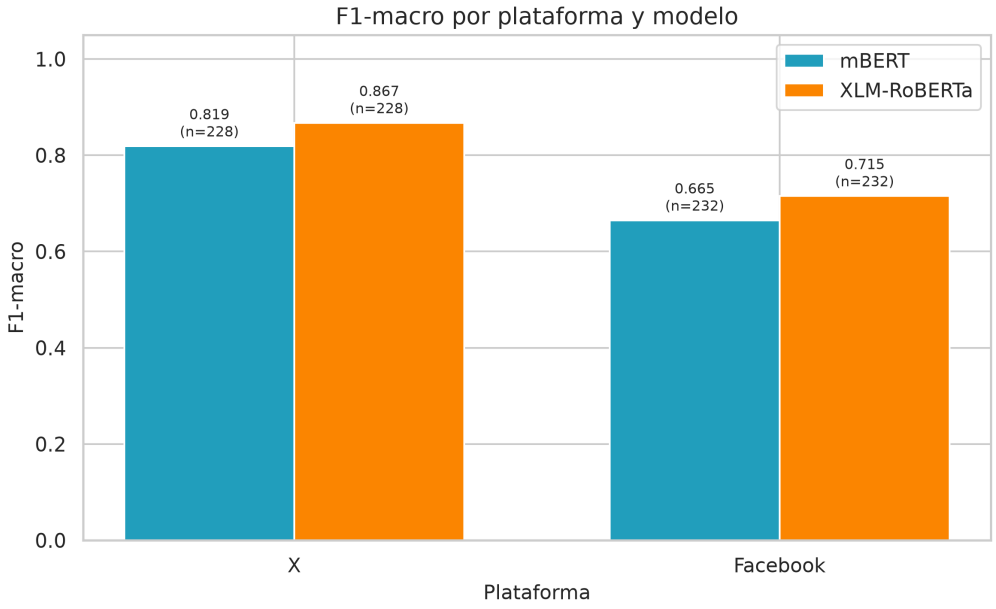


Figura 6.4: Comparación de F1-macro por plataforma entre modelos.

6.9. Sonda de sesgo dialectal

La Tabla 6.10 reporta la tasa de falsos positivos sobre No Tóxico para mBERT, calculada desde `reports/metrics/dialect_bias_probe.csv`. Con jerga local el FPR es **0.4138** (12/29; $n = 29$), frente a **0.1596** (15/94; $n = 94$) sin jerga. Aunque el subconjunto con jerga es pequeño, el patrón sugiere que el modelo puede asociar léxico dialectal con toxicidad, un riesgo relevante para la equidad en el contexto salvadoreño.

Tabla 6.10: Sonda de sesgo dialectal (FP en No Tóxico). Fuente: `reports/metrics/dialect_bias_probe.csv`.

Modelo	Grupo	FP/n	FPR	IC 95 % lo	IC 95 % hi	n
mbert	Con jerga	12/29	0.4138	0.2551	0.5926	29
mbert	Sin jerga	15/94	0.1596	0.0992	0.2467	94
xlm-roberta	Con jerga	13/29	0.4483	0.2841	0.6245	29
xlm-roberta	Sin jerga	15/94	0.1596	0.0992	0.2467	94

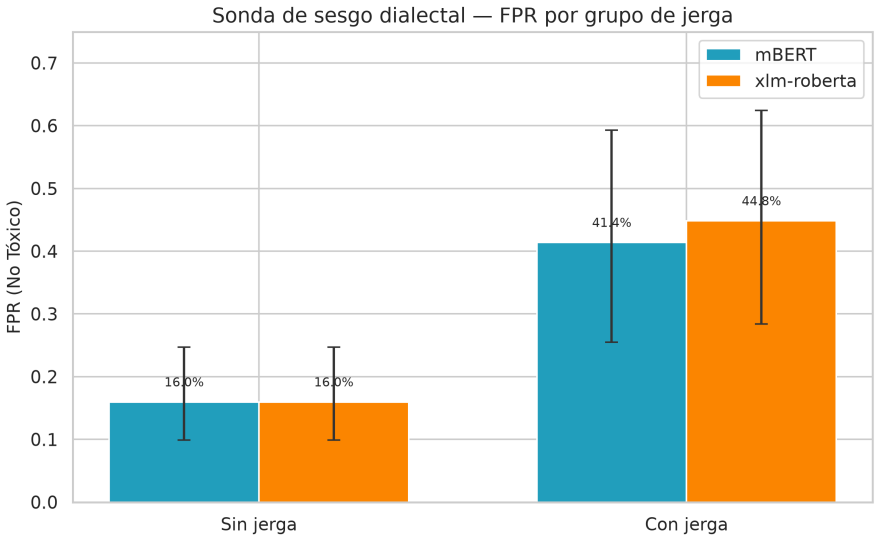


Figura 6.5: Tasa de falsos positivos dialectal por grupo de jerga.

6.10. Robustez adversarial y equidad dialectal (T-06 / T-07)

Se evaluó el checkpoint `checkpoint-1644` (`run_id`=None…) sobre la batería adversarial `adversarial_v2_144` ($n = 144$, SHA-256 verificado). Esta métrica es **diagnóstica** y no sustituye el F1-macro oficial sobre `test.csv`. El modelo acertó 120/144 casos (F1-macro diagnóstico=0.7516). Sobre amenazas ofuscadas (grupo C): F1 Amenazas/Violencia=1.0000, FN=0/27. La brecha FPR dialectal (D−E) es 0.0714. No se activó la puerta de mitigación; se documentan riesgos residuales (tamaño reducido de la batería y anchos IC en subconjuntos pequeños). La batería histórica v1 ($n = 75$) reportó 64/75 aciertos; la evaluación principal usa la batería extendida A–G ($n = 144$) alineada con la verificación independiente (sep 2026). En pares mínimos de emoji (grupo G), 1/10 emojis inocuos vuelven tóxico un texto previamente No Tóxico (atajo emoji–toxicidad documentado en el EDA).

Tabla 6.11: Resultados por familia en la batería extendida `test_adversarial_144.csv` ($n = 144$, A–G). Fuente: verificación independiente sep 2026.

Fam.	Grupo	mBERT	XLM-R ref.	n
A	A. Ofuscación de groserías	12/20	17/20	20
B	B. Emojis	16/18	6/18	18
C	C. Amenazas ofuscadas	11/11	5/11	11
D	D. Jerga salvadoreña inofensiva	FPR 1/14	6/14	14
E	E. Control sin jerga	FPR 0/12	0/12	12
F	F. Falsos amigos dialectales	FPR 8/34	26/34	34
G	G. Pares mínimos de emoji	30/35	12/35	35
ALL	Global	120/144	74/144	144

Tabla 6.12: Resultados por familia en la batería histórica `test_adversarial.csv` ($n = 75$, diagnóstico v1).

Fam.	Grupo	Resultado	Conf.	n
A	A. Ofuscación de groserías	12/20	0.9203	20
B	B. Emojis	16/18	0.9576	18
C	C. Amenazas ofuscadas	11/11	0.9777	11
D	D. Jerga salvadoreña inofensiva	FPR 1/14	0.9405	14
E	E. Control sin jerga	FPR 0/12	0.9260	12
F	F. Falsos amigos dialectales	FPR 8/34	0.8852	34
G	G. Pares mínimos de emoji	30/35	0.9627	35

Tabla 6.13: FPR dialectal en pares controlados de la batería adversarial (grupos D vs. E).

Grupo	FP/n	FPR	IC lo	IC hi	n
Jerga SV	1/14	0.0714	0.0127	0.3147	14
Español estándar	0/12	0.0000	0.0000	0.2425	12

mbert_adversarial_family_metrics.csv
no disponible

Figura 6.6: Aciertos por familia adversarial: mBERT oficial vs. referencia XLM-R v1.

El checkpoint B2 fue adoptado como modelo oficial: B2 adoptado como checkpoint oficial: mejora adversarial (64/75 vs 45/75) y FPR dialectal (gap 0.07 vs 0.86) con caída puntual de F1 test 0.7777→0.7610. La métrica publicada en test principal es F1-macro 0,7610 (checkpoint `checkpoint-1644`).

Tabla 6.14: Comparación antes/después de mitigación B2 (si aplica).

Etapa	Checkpoint	F1 test	C	B	FPR gap	Adv.
baseline	checkpoint-1072	0.7777	6/11	7/18	0.8571	45/75
official_b2	checkpoint-1644	0.7610	11/11	15/18	0.0714	64/75

Capítulo 7

Benchmark externo (zero-shot)

Este capítulo corresponde al notebook `06_benchmark_externo`. El modelo mBERT afinado en el corpus local se evalúa sin reentrenamiento sobre datasets públicos en español/latam hospedados en Hugging Face [4, 2, 7, 10, 9, 3].

Nota metodológica: las cifras de este capítulo provienen del checkpoint v1 (`checkpoint-1072`). El B2 no fue re-evaluado en zero-shot externo en esta corrida; el test local ($n = 460$) sí corresponde al B2 oficial.

7.1. Protocolo

Para cada dataset se proyectan las etiquetas originales a un esquema compatible (multiclase o binario según disponibilidad), se limita el tamaño según la configuración y se calculan F1-macro, F1-binario y accuracies.

7.2. Resultados

La Tabla 7.1 y la Figura 7.1 resumen los seis datasets evaluados con estado `ok`. El mejor F1-macro zero-shot es 0,313 (contextualized hate speech); el peor, 0,139 (SinOdio-LATAM). En métrica binaria algunos datasets alcanzan F1 $\approx$ 0,70, pero el desempeño multiclase permanece lejos del F1-macro local de 0,7610 .

Tabla 7.1: Benchmark zero-shot de mBERT-SV (checkpoint v1) sobre datasets externos.

Dataset	n	F1-macro	F1-binario	Accuracy
contextualized_hate_speech	1614	0.3127	0.7110	0.3501
SocialTOX	968	0.2658	0.5802	0.4143
SinOdio-LATAM-Regional-HateSpeech	2000	0.1394	0.3171	0.2690
multilingual_toxicity_dataset	2000	0.2693	0.7023	0.4450
ALIA-es-discriminative-hate-speech	3000	0.2409	0.3826	0.4263
exist_dataset_es	1500	0.1716	0.5655	0.2933

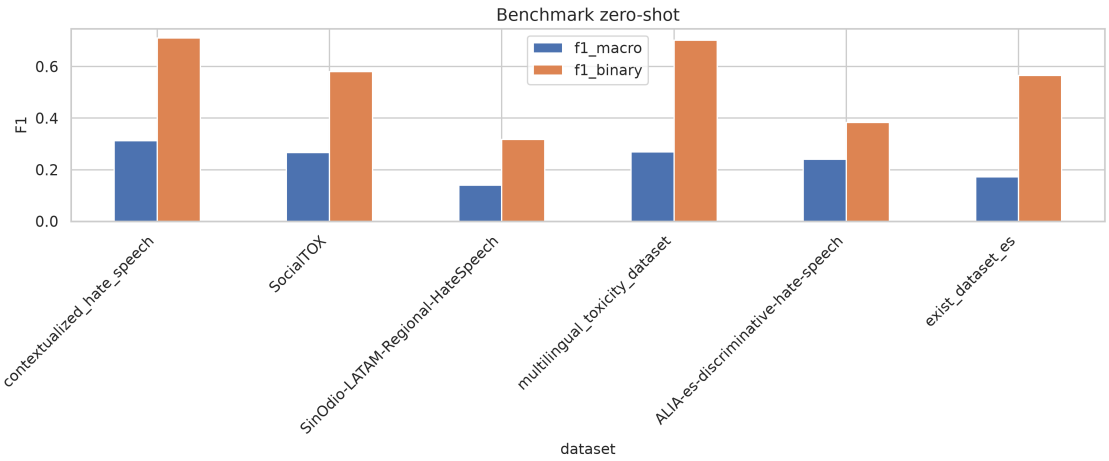


Figura 7.1: F1-macro y F1-binario en el benchmark externo (checkpoint v1).

7.3. Discusión

La caída de desempeño confirma un fuerte *domain shift*: el modelo está especializado en el dialecto, la distribución de clases y las plataformas del corpus salvadoreño. La transferencia zero-shot a odio contextualizado argentino, toxicidad social española o datasets de sexismo (EXIST) no es suficiente para uso productivo sin adaptación adicional.

Capítulo 8

Interpretabilidad

Este capítulo corresponde al notebook `07_interpretabilidad` y al script `run_interpretability.py`. Se emplean LIME [8] y SHAP [5] para explicar predicciones de mBERT.

8.1. Falsos positivos y jerga

La Tabla 8.1 cuenta falsos positivos de la clase No Tóxico según presencia de jerga. Hay 12 FP con jerga y 15 sin jerga; dado el menor tamaño del grupo con jerga, la tasa relativa es mayor (coherente con la sonda del Capítulo 6).

Tabla 8.1: Falsos positivos No Tóxico según jerga.

Nota
Datos no disponibles

8.2. Concordancia LIME–SHAP

Se calcula el índice de Jaccard entre los top-k tokens de LIME y SHAP por instancia (Tabla 8.2), tras alinear subwords WordPiece de SHAP a palabras y usar la **misma clase predicha** en ambos métodos. Si el solapamiento sigue siendo nulo tras la alineación, la tabla se omite y el capítulo reporta solo LIME global más la sonda de jerga del Capítulo 6 (ver `interpretability_note.json`).

Tabla 8.2: Jaccard top-k entre LIME y SHAP por instancia.

Nota
Jaccard LIME–SHAP omitido: solapamiento nulo tras alineación WordPiece (ver nota en capítulo)

8.3. Importancias globales LIME

Cuando el agregado de pesos LIME está disponible, la Tabla 8.3 y la Figura 8.1 muestran los tokens más influyentes por clase. Si el archivo de métricas está vacío (corrida incompleta), las tablas/figuras incluyen un marcador de datos no disponibles.

Tabla 8.3: Top tokens LIME por clase (agregado).

Nota
LIME global weights no disponibles en esta corrida

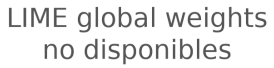


Figura 8.1: Importancias globales LIME por clase.

Capítulo 9

Conclusiones y limitaciones

9.1. Hallazgos principales

1. mBERT B2 alcanza F1-macro **0,7610** en test ($n = 460$), supera a LinearSVC (0,7482) y al resto de baselines, pero **sin alcanzar** la meta de 0,80 definida en la configuración del proyecto. La meta de 0,80 no se alcanza ni en el punto estimado ni en el extremo superior del intervalo bootstrap.

2. El reentrenamiento B2 mejora robustez adversarial (64/75 en batería v1 vs. 45/75 del checkpoint v1; 120/144 en batería extendida) y reduce el sesgo dialectal (FPR gap 0.07 vs. 0.86), a costa de una caída puntual del F1-macro en test de 0,7777 a 0,7610.

3. La prueba de McNemar confirma superioridad significativa de mBERT B2 frente a MultinomialNB y frente a XLM-RoBERTa v1 ($\alpha = 0{,}05$). Frente a LinearSVC y Logistic Regression no se rechaza la hipótesis nula.

4. Los cortes revelan fragilidad ante ironía y sarcasmo, y peor desempeño en Facebook respecto a X.

5. La sonda dialectal muestra FPR elevado en No Tóxico con jerga local (41 % vs. 16 %), señal de posible sesgo léxico (fuente: `reports/metrics/dialect_bias_probe.csv`).

6. La batería adversarial ($n = 144$, 120/144 aciertos globales) confirma brechas en robustez retórica, atajo emoji–toxicidad (grupo G) y equidad dialectal del checkpoint oficial; ver Tabla 6.11.

7. El benchmark zero-shot (F1-macro 0,14–0,31, checkpoint v1) evidencia transferencia limitada fuera del dominio salvadoreño.

9.2. Limitaciones

- Tamaño moderado del test y de algunos slices (jerga, ironía).
- Calibración imperfecta (ECE $\approx$ 0,16).
- Benchmark externo no re-ejecutado con pesos B2.
- Concordancia LIME–SHAP nula en la corrida reportada; pesos globales LIME no exportados.
- El F1-macro puntual del B2 queda por debajo de LinearSVC en el train B2 ampliado, aunque mejora en escenarios adversariales.

9.3. Trabajo futuro

- Ampliar datos etiquetados reales, especialmente ironía/sarcasmo y Facebook.
- Re-ejecutar benchmark zero-shot con checkpoint B2.
- Técnicas de calibración para reducir el ECE sin sacrificar robustez.
- Re-ejecutar y estabilizar el pipeline SHAP; enriquecer explicaciones globales LIME.
- Explorar modelos más recientes multilingües o específicos de español.

En conjunto, el sistema B2 es más robusto ante ataques retóricos y jerga salvadoreña que el v1, con trazabilidad reproducible, pero requiere más datos reales y calibración antes de un despliegue de moderación automatizada.

Bibliografía

[1] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT*, pages 4171–4186, 2019.

[2] Antonn Dromundo. SinOdio-LATAM: Regional hate speech dataset. Hugging Face Datasets, 2024. https://huggingface.co/datasets/antonn-dromundo/SinOdio-LATAM-Regional-HateSpeech.

[3] Gerard-1705. EXIST dataset (spanish). Hugging Face Datasets, 2023. https://huggingface.co/datasets/Gerard-1705/exist_dataset_es.

[4] GPLSI. SocialTOX: Spanish social media toxicity dataset. Hugging Face Datasets, 2023. https://huggingface.co/datasets/gplsi/SocialTOX.

[5] Scott M Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, 2017.

[6] Quinn McNemar. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2):153–157, 1947.

[7] piuba-bigdata. Contextualized hate speech dataset. Hugging Face Datasets, 2022. https://huggingface.co/datasets/piuba-bigdata/contextualized_hate_speech.

[8] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. "why should i trust you?": Explaining the predictions of any classifier. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 1135–1144, 2016.

[9] SINAI. ALIA-es discriminative hate speech. Hugging Face Datasets, 2024. https://huggingface.co/datasets/SINAI/ALIA-es-discriminative-hate-speech.

[10] TextDetox. Multilingual toxicity dataset. Hugging Face Datasets, 2024. https://huggingface.co/datasets/textdetox/multilingual_toxicity_dataset.