ANÁLISIS DEL DISCURSO DE ODIO EN REDES SOCIALES EN EL SALVADOR

INFORME DE MÉTRICAS — mBERT v6

Julio Enrique De La Quadra Mata
Cristian Antonio Escalante Hernandez
Willian Alexander Chávez Servellón

Universidad de El Salvador
Facultad de Ingeniería y Arquitectura
Escuela de Sistemas Informáticos

Ciudad universitaria, 3 de noviembre de 2026

Índice general

Resumen ejecutivo **3**

1. Introducción **4**
1.1. Problema . . . 4
1.2. Esquema de clases . . . 4
1.3. Objetivos y métrica principal . . . 4
1.4. Resumen ejecutivo de resultados . . . 5

2. Metodología **6**
2.1. Datos y particiones . . . 6
2.1.1. Evolución del corpus . . . 6
2.1.2. Motivación histórica del reentrenamiento . . . 6
2.2. Pipeline experimental . . . 6
2.3. Métricas de evaluación . . . 7
2.3.1. Pisos triviales sin modelo . . . 7
2.4. Cortes (slices) . . . 7
2.4.1. Batería adversarial diagnóstica . . . 7
2.5. Contrato de inferencia . . . 7

3. Análisis exploratorio de datos **8**
3.1. Distribución de clases . . . 8
3.2. Baselines triviales . . . 8
3.3. Plataforma y longitud de tokens . . . 9

4. Preprocesamiento y baselines TF-IDF **11**
4.1. Normalización y features . . . 11
4.2. Baselines TF-IDF . . . 11

5. Fine-tuning de mBERT v6 **12**
5.1. Configuración de entrenamiento . . . 12
5.2. Pesos de clase . . . 12
5.3. Métricas de validación . . . 12
5.4. Comparación con checkpoints históricos . . . 13

6. Evaluación completa y comparación **14**
6.1. Métricas globales de mBERT . . . 14
6.2. Desempeño por clase . . . 14
6.3. Comparación de modelos . . . 15
6.4. Trazabilidad de la métrica oficial . . . 16
6.5. Evolución v1, B2 y v6 . . . 16
6.6. Score operativo (SLO) . . . 16
6.7. Pruebas de McNemar . . . 17

6.8. Métricas por cortes (slices) . . . 17
6.9. Desempeño por plataforma . . . 19
6.9.1. XLM-RoBERTa . . . 19
6.10. Sonda de sesgo dialectal . . . 20
6.11. Robustez adversarial y equidad dialectal (T-06 / T-07) . . . 21

7. Benchmark externo (zero-shot) 24
7.1. Protocolo . . . 24
7.2. Resultados . . . 24
7.3. Discusión . . . 25

8. Interpretabilidad 26
8.1. Falsos positivos y jerga . . . 26
8.2. Concordancia LIME–SHAP . . . 26
8.3. Importancias globales LIME . . . 26

9. Conclusiones y limitaciones 28
9.1. Hallazgos principales . . . 28
9.2. Limitaciones . . . 28
9.3. Trabajo futuro . . . 29

Resumen ejecutivo

Este informe documenta la evaluación del modelo **mBERT v6** (`bert-base-multilingual-cased`, checkpoint `checkpoint-4050`) entrenado sobre el corpus CDE **v1.9.0** (train n = 21,585; val n = 459; test n = 460 sin cambios respecto a corridas anteriores).

Sobre el conjunto de prueba (n = 460), el modelo mBERT v6 alcanza un **F1-macro de 0,7784** (intervalo bootstrap 95 %: [0,7408, 0,8151]), superando a los baselines TF-IDF disponibles. El objetivo de 0,80 no se alcanza en el punto estimado, aunque el intervalo de confianza superior lo incluye.

Tabla 1: Métricas globales oficiales (test, n = 460).

Métrica	Valor
Accuracy	0.7804
Balanced accuracy	0.7776
F1-macro	0.7784
F1-weighted	0.7807
MCC	0.7011
QWK	0.7286
Kappa lineal	0.7118
Ordinal MAE	0.3348
Ordinal RMSE	0.7746
Errores grandes (%)	9.7826
ROC-AUC OVR	0.9289
Log-loss	0.9722
ECE	0.1777
Brier macro	0.0938
F1 bootstrap lo	0.7408
F1 bootstrap hi	0.8151

Los cortes más difíciles siguen siendo ironía y sarcasmo (baja potencia estadística); Facebook presenta menor F1-macro que X. La batería adversarial extendida (n = 144) alcanza 122/144 aciertos con gap FPR dialectal 0,07. Frente a checkpoints históricos, v6 recupera F1-macro en test (0,7784) por encima de B2 (0,7610) y ligeramente por encima de v1 (0,7777), con score operativo SLO aún por debajo de la meta 0,90 por el corte Facebook.

Capítulo 1

Introducción

1.1. Problema

El discurso de odio y la toxicidad en redes sociales constituyen un desafío creciente para la moderación de contenidos, en especial en contextos dialectales poco representados en los corpus de entrenamiento masivos. Este informe documenta el desarrollo y la evaluación de un sistema de clasificación multiclase de toxicidad aplicado a publicaciones de redes sociales de El Salvador (plataformas X/Twitter y Facebook).

El problema se formula como clasificación ordinal de cuatro niveles de gravedad, donde el modelo debe distinguir entre contenido no tóxico, lenguaje ofensivo, discurso de odio y amenazas o violencia.

1.2. Esquema de clases

Las etiquetas son ordinales (0–3) y se resumen en la Tabla 1.1.

Tabla 1.1: Esquema de clases del corpus.

Label	Clase
0	No Tóxico
1	Lenguaje Ofensivo
2	Discurso de Odio
3	Amenazas/Violencia

1.3. Objetivos y métrica principal

El objetivo principal del proyecto es entrenar un modelo *mBERT* (`bert-base-multilingual-cased`) [1] mediante fine-tuning sobre el corpus local y alcanzar un F1-macro de al menos **0,80** en el conjunto de prueba, según la meta definida en la configuración del proyecto.

Además se buscan:

- Establecer baselines clásicos (TF-IDF + clasificadores lineales).
- Evaluar robustez por cortes (plataforma, jerga, sarcasmo, ironía).
- Medir transferencia zero-shot a corpora externos en español.
- Explorar interpretabilidad con LIME [7] y SHAP [5].

1.4. Resumen ejecutivo de resultados

Sobre el conjunto de prueba ($n = 460$), el modelo mBERT v6 alcanza un **F1-macro de 0,7784** (intervalo bootstrap 95 %: [0,7408, 0,8151]), superando a los baselines TF-IDF disponibles. El objetivo de 0,80 no se alcanza en el punto estimado, aunque el intervalo de confianza superior lo incluye.

En evaluación zero-shot sobre seis datasets externos, el F1-macro cae al rango 0,14–0,31, lo que indica transferencia limitada fuera del dominio local. Los cortes más difíciles son ironía (F1 ≈ 0.50) y sarcasmo (F1 ≈ 0.62), mientras que el desempeño en la plataforma X es sólido (F1 $\approx$ 0.83).

Los capítulos siguientes siguen el orden de los notebooks reproducibles del proyecto (01–07): análisis exploratorio, preprocesamiento, baselines, fine-tuning, evaluación completa, benchmark externo e interpretabilidad.

Capítulo 2

Metodología

2.1. Datos y particiones

El corpus procesado reside en `data/processed/` con particiones `train.csv`, `val.csv` y `test.csv`. La release **v6** (CDE **v1.9.0**) usa train n = 21,585, val n = 459 y test n = 460. El archivo `test.csv` conserva el mismo hash SHA-256 que en v1 y B2, lo que garantiza comparabilidad directa entre checkpoints.

Cada instancia incluye el texto de entrada del modelo (`texto_modelo`), la etiqueta ordinal, metadatos de plataforma e indicadores de sarcasmo, ironía, contexto político y conteo de jerga local (`n_jerga`).

2.1.1. Evolución del corpus

El checkpoint v1 entrenó con n = 2,144 reales; B2 amplió el train a 3,293 instancias (sintéticos dirigidos). v6 integra anotación gold y política `b2_full` sobre el release congelado `versiones/v6/dataset/`, inicializando pesos desde v4 (`versiones/v4/model`).

2.1.2. Motivación histórica del reentrenamiento

La auditoría del checkpoint v1 identificó cuatro huecos: atajo emoji⇒tóxico, emojis de ataque no vistos, amenazas ofuscadas y sesgo dialectal. Los releases B2 y v6 abordan robustez adversarial y equidad sin cambiar el test oficial.

2.2. Pipeline experimental

El flujo de trabajo es reproducible y se alinea con los notebooks 01–07:

1. Análisis exploratorio (distribuciones, plataformas, longitudes).
2. Normalización de texto y extracción de features (pesos de clase, indicadores dialectales).
3. Baselines TF-IDF (Logistic Regression, LinearSVC, MultinomialNB).
4. Fine-tuning de mBERT [1] sobre `versiones/v6/model` (checkpoint publicado en Hugging Face `caeher/mbert-sv`).
5. Evaluación completa: métricas globales, por clase, por cortes, SLO de producción y comparación descriptiva de modelos.
6. Benchmark zero-shot sobre datasets públicos de Hugging Face (checkpoint v1; no re-ejecutado en v6).
7. Interpretabilidad con LIME [7] y SHAP [5].

2.3. Métricas de evaluación

Se implementa un conjunto amplio de métricas en el módulo de evaluación del proyecto:

- **Clásicas:** accuracy, balanced accuracy, precision/recall/F1 (macro y weighted), MCC.
- **Ordinales:** MAE, RMSE y porcentaje de errores grandes ($|y - \hat{y}| \geq 2$).
- **Acuerdo:** kappa lineal y Quadratic Weighted Kappa (QWK).
- **Probabilísticas:** ROC-AUC OVR macro, log-loss, ECE y Brier macro.
- **Incertidumbre:** intervalo de confianza bootstrap del F1-macro (1000 remuestreos, $\alpha = 0{,}05$).
- **Score operativo:** agregado definido en `production_slo_v1.json` (cortes mínimos, recall de amenazas y restricciones adversariales).

La métrica de decisión principal es el **F1-macro**, que trata por igual las cuatro clases y es adecuada ante desbalance.

2.3.1. Pisos triviales sin modelo

Los baselines de referencia (clase mayoritaria, azar uniforme y azar estratificado) se calculan sobre la distribución del **test** ($n = 460$) con $k = 4$ clases fijas.

2.4. Cortes (slices)

Además del desempeño global, se calculan métricas sobre subconjuntos definidos en el test (plataforma, jerga, sarcasmo, ironía y contexto político). Los cortes de mBERT v6 se derivan del vector de predicciones oficial (`mbert_test_predictions.csv`, checkpoint `checkpoint-4050`) y se exportan en `reports/metrics/slice_metrics.csv`.

2.4.1. Batería adversarial diagnóstica

Existen dos conjuntos adversariales: `test_adversarial.csv` ($n = 75$) y `test_adversarial_144.csv` ($n = 144$, familias A–G). Son **exclusivamente diagnósticos**: no entrenan ni seleccionan el modelo, y no sustituyen el F1-macro oficial sobre `test.csv`.

2.5. Contrato de inferencia

Entrenamiento, evaluación por lote e inferencia del prototipo XLM-R comparten un contrato versionado (`inference_contract.json`): `max_length`=128, columna `texto_modelo` y normalizador `normalize_for_model` v1.1. La auditoría reportó F1-macro 0.8058 con evaluación a `max_length`=256; bajo el contrato oficial (`max_length`=128, normalizador normalize_for_model v1.1), el F1-macro es 0.8058 (0.0 % de predicciones distintas frente a la ruta diagnóstica a 256, F1=0.8058). Sin normalización sobre texto crudo, 1.74 % de las predicciones cambian respecto al contrato.

Capítulo 3

Análisis exploratorio de datos

Este capítulo corresponde al notebook `01_eda`. Se describe la distribución de clases, la composición por plataforma y la longitud de los textos tokenizados.

3.1. Distribución de clases

La Figura 3.1 muestra el conteo por clase en el corpus. Existe desbalance: la clase Lenguaje Ofensivo es la más frecuente, mientras que Amenazas/Violencia es minoritaria. Este desbalance motiva el uso de pesos de clase y la elección de F1-macro como métrica principal.

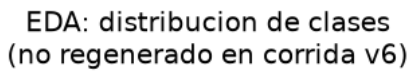


Figura 3.1: Distribución de clases en el corpus.

3.2. Baselines triviales

Antes de entrenar modelos, se estiman baselines triviales sobre el **conjunto de test** ($n = 460$; Tabla 3.1): clase mayoritaria, azar uniforme y azar estratificado. Para la clase mayoritaria se simula un clasificador que siempre predice la etiqueta más frecuente: precisión p (proporción en test), recall 1,0; el F1 de las demás clases es 0. El F1-macro es la media sobre $k = 4$ clases. Los valores del CSV se redondean a tres decimales (`round`); la tabla generada muestra cuatro. El

informe de preparación v1.1 reportaba $\approx 0{,}129$ por un redondeo intermedio de p; aquí 0,128. El azar se sitúa en 0,25. Cualquier modelo útil debe superar claramente estos umbrales.

Tabla 3.1: Baselines triviales (F1-macro).

Baseline	F1-macro
azar_estratificado	0.2500
azar_uniforme	0.2500
clase_mayoritaria	0.1284

3.3. Plataforma y longitud de tokens

La Figura 3.2 desglosa las clases por plataforma. X concentra más volumen; Facebook presenta una distribución distinta que, como se verá en la evaluación por cortes, resulta más difícil para el modelo.

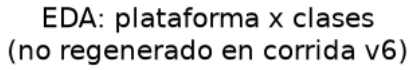


Figura 3.2: Distribución de clases por plataforma.

La Figura 3.3 muestra la longitud en tokens del texto de entrada. La mayoría de instancias cabe cómodamente bajo el `max_length` de 128 tokens usado en mBERT.

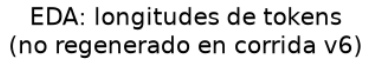


Figura 3.3: Distribución de longitudes en tokens.

Capítulo 4

Preprocesamiento y baselines TF-IDF

Este capítulo agrupa los notebooks `02_preprocesamiento_features` y `03_baselines_tfidf`.

4.1. Normalización y features

El pipeline de normalización produce `texto_modelo` (texto limpio para el clasificador) y features auxiliares: conteos de caracteres/palabras, emojis, menciones, hashtags, ratio de mayúsculas y, de forma crítica para el análisis dialectal, el conteo de jerga salvadoreña (`n_jerga`).

Para mitigar el desbalance se calculan pesos de clase (Tabla 4.1). Amenazas/Violencia y Discurso de Odio reciben pesos mayores que Lenguaje Ofensivo, la clase más frecuente.

Tabla 4.1: Pesos de clase usados en el entrenamiento.

Nota
Datos no disponibles

4.2. Baselines TF-IDF

Se entrenan tres clasificadores clásicos sobre un vectorizador TF-IDF (n-gramas 1–2, máximo 10 000 features, `sublinear_tf`):

- Logistic Regression (class_weight balanced).
- LinearSVC (class_weight balanced).
- MultinomialNB.

Los resultados en test se muestran en la Tabla 4.2. LinearSVC obtiene el mejor F1-macro (0,765), seguido de Logistic Regression (0,758) y MultinomialNB (0,648). Todos superan ampliamente los baselines triviales del Capítulo 3.

Tabla 4.2: Baselines TF-IDF en el conjunto de prueba (F1-macro).

Nota
Datos no disponibles

Estos baselines constituyen el piso competitivo frente al cual se evalúa mBERT en el Capítulo 6.

Capítulo 5

Fine-tuning de mBERT v6

Este capítulo corresponde al notebook `04_finetuning_mbert`. Se describe el entrenamiento de `bert-base-multilingual-cased` [1] sobre CDE v1.9.0 con inicialización desde el release v4.

5.1. Configuración de entrenamiento

Los hiperparámetros principales (GPU, `training_run.json`) se resumen en la Tabla 5.1.

Tabla 5.1: Hiperparámetros de fine-tuning v6 (Transformers).

Parámetro	Valor
Modelo base	`bert-base-multilingual-cased`
Directorio de salida	`versiones/v6/model`
Train / val	21,585 / 459
Épocas	5
Batch size (train / eval)	16 / 32
Learning rate	2×10^{-5}
Warmup ratio	0,1
Weight decay	0,01
Max length	128
Label smoothing	0,0
Pérdida	CE + peso ordinal 0,3
Semilla	42

5.2. Pesos de clase

Los pesos publicados en el metadata del dataset (Tabla 4.1) mitigan el desbalance; la receta v6 mantiene masa efectiva en amenazas sintéticas (`threat_synthetic_effective_n`≈ 90).

5.3. Métricas de validación

El mejor checkpoint (`checkpoint-4050`, paso global 4050) alcanza en validación un F1-macro de **0,8157** y accuracy **0,8235** (`training_run.json`). La Figura 5.1 resume las métricas finales de validación exportadas; el historial completo de pérdida por step no se versiona en Git.

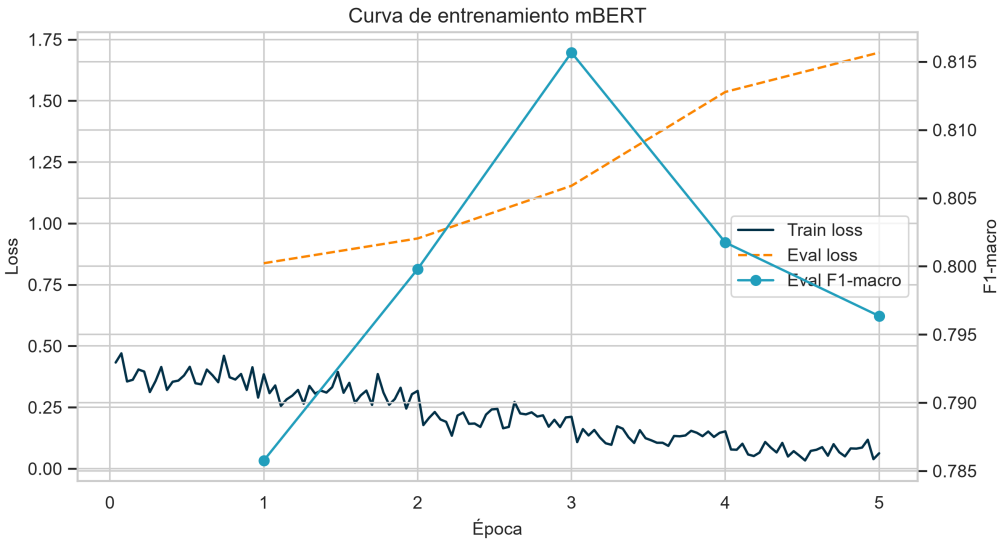


Figura 5.1: Curva de entrenamiento: métricas finales de validación v6.

El checkpoint oficial se congela en `versiones/v6/model/` (pesos en Hugging Face). El contrato de inferencia (`inference_contract.json`) fija `max_length=128`, columna `texto_modelo` y normalizador `normalize_for_model` v1.1.

5.4. Comparación con checkpoints históricos

El checkpoint v1 (`checkpoint-1072`) alcanzaba F1-macro **0,7777** en test; B2 (`checkpoint-1644`) **0,7610**, priorizando robustez adversarial. v6 recupera **0,7784** en test con 71/75 y 122/144 aciertos adversariales y gap FPR dialectal 0,07 (Capítulo 6).

Capítulo 6

Evaluación completa y comparación

Este capítulo (notebook `05_metricas_y_comparacion`) concentra los resultados centrales del proyecto sobre el conjunto de prueba ($n = 460$).

6.1. Métricas globales de mBERT

El F1-macro es **0,7784**, con intervalo bootstrap 95 % [0,7408, 0,8151]. La accuracy es 0,7804 y el MCC 0,7011. El QWK de 0,7286 indica buen acuerdo ordinal. El ECE de 0,1777 sugiere margen de mejora en calibración.

Tabla 6.1: Métricas globales de mBERT en test.

Métrica	Valor
Accuracy	0.7804
Balanced accuracy	0.7776
F1-macro	0.7784
F1-weighted	0.7807
MCC	0.7011
QWK	0.7286
Kappa lineal	0.7118
Ordinal MAE	0.3348
Ordinal RMSE	0.7746
Errores grandes (%)	9.7826
ROC-AUC OVR	0.9289
Log-loss	0.9722
ECE	0.1777
Brier macro	0.0938
F1 bootstrap lo	0.7408
F1 bootstrap hi	0.8151

6.2. Desempeño por clase

Lenguaje Ofensivo obtiene el mejor F1 (0,7987), seguido de No Tóxico (0,7717). Discurso de Odio es la clase más débil (0,7604), aunque el soporte es menor.

Tabla 6.2: Métricas por clase mBERT (test).

Clase	Precision	Recall	F1	Support
No Tóxico	0.7481	0.7967	0.7717	123
Lenguaje Ofensivo	0.8117	0.7862	0.7987	159
Discurso de Odio	0.7526	0.7684	0.7604	95
Amenazas/Violencia	0.8077	0.7590	0.7826	83

La matriz de confusión (Figura 6.1) confirma confusiones preferentemente entre clases adyacentes en la escala ordinal (p. ej. ofensivo ↔ odio), coherente con el MAE ordinal de 0,335.

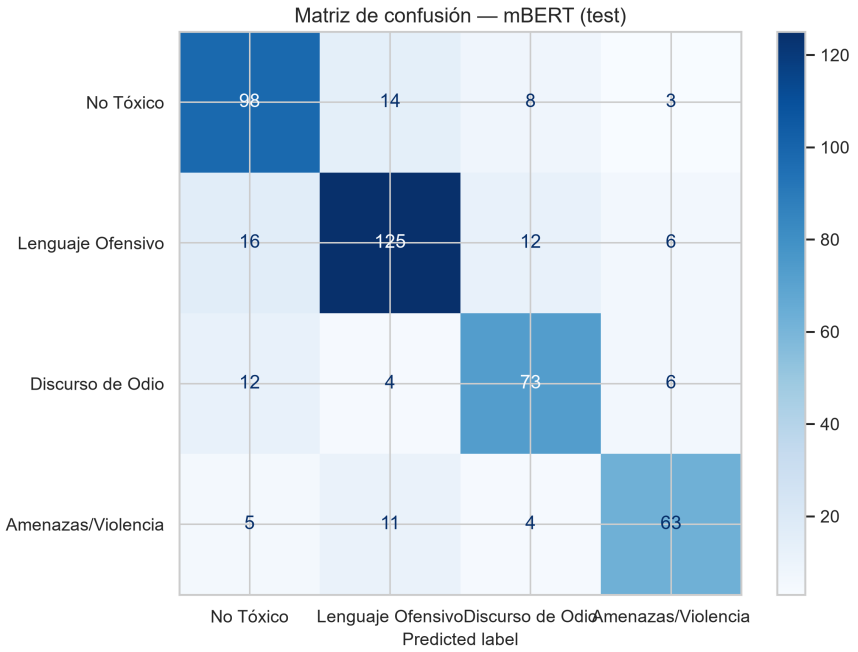


Figura 6.1: Matriz de confusión de mBERT en el conjunto de prueba.

6.3. Comparación de modelos

La Tabla 6.3 y la Figura 6.2 ordenan los modelos por F1-macro de forma **descriptiva**. El ranking puntual no establece por sí solo superioridad estadística entre arquitecturas transformer: la comparación pareada mBERT vs. XLM-RoBERTa se evalúa con McNemar en la sección siguiente sobre las mismas $n = 460$ instancias. mBERT v6 obtiene F1-macro puntual 0,7784.

Tabla 6.3: Comparación de modelos (F1-macro en test).

Modelo	F1-macro
XLM-RoBERTa	0.8058
mBERT	0.7784
trivial_azar_estratificado	0.2500
trivial_azar_uniforme	0.2500
trivial_clase_mayoritaria	0.1284

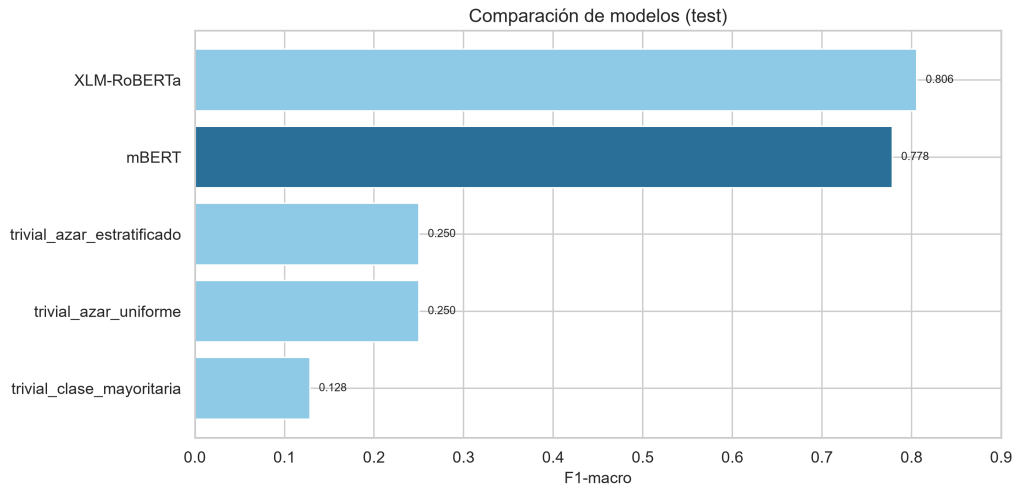


Figura 6.2: Comparación de F1-macro entre modelos.

6.4. Trazabilidad de la métrica oficial

La Tabla 6.4 documenta cada cifra histórica de F1-macro citada para mBERT. La métrica **oficial** (0,7784) proviene del checkpoint `checkpoint-4050` (semilla 42, hash de test `b63a04906bedda1b...`, evaluación `2026-11-03`). La cifra 0,7862 del informe de auditoría queda archivada como *no reproducible*. Los checkpoints v1 (0,7777) y B2 (0,7610) se conservan como referencia histórica en la misma tabla.

Tabla 6.4: Trazabilidad de F1-macro mBERT (histórico vs. oficial).

F1-macro	Estado	Fuente	Checkpoint	Sp
0.7784	Oficial	reports/metrics/mbert_test_metrics.csv	checkpoint-4050	tes
0.7780	Mismo run (redondeo)	reports/latex/chapters (histórico)	checkpoint-4050	tes
0.7862	No reproducible	Informe_Auditoria_de_Modelos.docx (Tabla 7)	desconocido	tes
0.7777	Histórico reproducible	models/mbert-sv (checkpoint-1072)	checkpoint-1072	tes
0.8157	Solo validación	models/mbert-sv-b2/train_metrics.json / val	checkpoint-4050	val

6.5. Evolución v1, B2 y v6

La Tabla 6.4 documenta la evolución del F1-macro. En test, v1 alcanzaba 0,7777, B2 0,7610 (mayor robustez adversarial) y v6 0,7784. En batería $n = 75$, v6 reporta 71/75 aciertos (B2: 64/75; v1: 45/75); en $n = 144$, v6 alcanza 122/144. En plataforma, Facebook pasa de F1 0,665 (B2) a 0,696 (v6); X se mantiene en torno a 0,826.

6.6. Score operativo (SLO)

El baseline `production_slo_baseline_v6_gold.json` evalúa el contrato `production_slo_v1.json` sobre el checkpoint oficial. El **score operativo** es 0,6963 frente a meta 0,90 (`slo_pass: false`). Componentes limitantes: F1-macro mínimo por corte (`min_required_slice_f1_macro`= 0,6963, Facebook) y recall de Amenazas/Violencia (0,759, umbral 0,759). Las restricciones adversariales (75/45 aciertos mínimos, gap FPR dialectal $\leq 0{,}17$) sí se cumplen.

6.7. Pruebas de McNemar

La Tabla 6.5 reporta comparaciones pareadas exportadas en `mcnemar_tests.csv` cuando están disponibles. Deben interpretarse junto con el F1-macro bootstrap oficial; si el CSV no se regeneró sobre v6, la tabla puede reflejar rutas de checkpoint históricas.

La comparación pareada mBERT vs. XLM-RoBERTa sobre las mismas $n = 460$ instancias de test arroja $p = 0{,}041391$ ($b = 26$, $c = 44$; $\alpha = 0{,}05$): la diferencia **es estadísticamente significativa** bajo el umbral definido. Frente a MultinomialNB la superioridad de mBERT sí alcanza significancia estadística ($\alpha = 0{,}05$).

Tabla 6.5: Pruebas de McNemar pareadas (mBERT vs. baselines y XLM-RoBERTa).

Modelo A	Modelo B	Estadístico	p-valor	b	c	n	Sig.
mBERT	LogisticRegression	0.5619	0.241432	59	46	460	No
mBERT	LinearSVC	0.5376	0.534060	50	43	460	No
mBERT	MultinomialNB	0.6389	0.005024	69	39	460	Sí
mBERT	XLM-RoBERTa	0.3714	0.041391	26	44	460	Sí

6.8. Métricas por cortes (slices)

La Tabla 6.6 y la Figura 6.3 muestran el F1-macro por subconjunto. Las filas mBERT comparten `run_id` y checkpoint con la evaluación oficial (T-04); la Tabla 6.7 detalla métricas por clase en cortes con $n \geq 30$. Destacan:

- **Plataforma X** (F1 **0.8257**) vs. **Facebook** (F1 **0.6963**): brecha importante.
- **Ironía** (F1 **0.4975** (baja potencia: faltan clases (n=59))) y **sarcasmo** (F1 **0.6222**) degradan el desempeño respecto a sus contrapartes sin figura retórica (F1 0.7911 e 0.7921).
- Contexto político muestra peor desempeño (F1 0.7131 vs. 0.7624).
- Fuente: `reports/metrics/slice_metrics.csv`.

Tabla 6.6: F1-macro y accuracy por cortes (definición, n, distribución de clases).

Modelo	Corte	Definición	n	Clases	F
mBERT	con_jerga	n_jerga >0	278	29/117/72/60	
mBERT	contexto_politico_no	Contexto_Politico in {NO/FALSE/0/N}	368	107/97/93/71	
mBERT	contexto_politico_si	Contexto_Politico in {SI/SÍ/YES/TRUE/1}	92	16/62/2/12	
mBERT	ironia_no	Presencia_Ironia in {NO/FALSE/0/N}	401	94/136/88/83	
mBERT	ironia_si	Presencia_Ironia in {SI/SÍ/YES/TRUE/1}	59	29/23/7/0	
mBERT	plataforma_Facebook	Plataforma == 'Facebook'	232	75/88/30/39	
mBERT	plataforma_X	Plataforma == 'X'	228	48/71/65/44	
mBERT	sarcasmo_no	Presencia_Sarcasmo in {NO/FALSE/0/N}	370	91/111/87/81	
mBERT	sarcasmo_si	Presencia_Sarcasmo in {SI/SÍ/YES/TRUE/1}	90	32/48/8/2	
mBERT	sin_jerga	n_jerga == 0	182	94/42/23/23	

Tabla 6.7: Métricas por clase en cortes mBERT con muestra suficiente ($n \geq 30$).

Corte	Clase	Support	Precision	Recall	F1
con_jerga	No Tóxico	29	0.7826	0.6207	0.6923
con_jerga	Lenguaje Ofensivo	117	0.8909	0.8376	0.8634
con_jerga	Discurso de Odio	72	0.7647	0.9028	0.8280
con_jerga	Amenazas/Violencia	60	0.8167	0.8167	0.8167
contexto_politico_no	No Tóxico	107	0.7455	0.7664	0.7558
contexto_politico_no	Lenguaje Ofensivo	97	0.7228	0.7526	0.7374
contexto_politico_no	Discurso de Odio	93	0.7912	0.7742	0.7826
contexto_politico_no	Amenazas/Violencia	71	0.8030	0.7465	0.7737
contexto_politico_si	No Tóxico	16	0.7619	1.0000	0.8649
contexto_politico_si	Lenguaje Ofensivo	62	0.9811	0.8387	0.9043
contexto_politico_si	Discurso de Odio	2	0.1667	0.5000	0.2500
contexto_politico_si	Amenazas/Violencia	12	0.8333	0.8333	0.8333
ironia_no	No Tóxico	94	0.7282	0.7979	0.7614
ironia_no	Lenguaje Ofensivo	136	0.8162	0.8162	0.8162
ironia_no	Discurso de Odio	88	0.7841	0.7841	0.7841
ironia_no	Amenazas/Violencia	83	0.8514	0.7590	0.8025
ironia_si	No Tóxico	29	0.8214	0.7931	0.8070
ironia_si	Lenguaje Ofensivo	23	0.7778	0.6087	0.6829
ironia_si	Discurso de Odio	7	0.4444	0.5714	0.5000
ironia_si	Amenazas/Violencia	0	0.0000	0.0000	0.0000
plataforma_Facebook	No Tóxico	75	0.6923	0.8400	0.7590
plataforma_Facebook	Lenguaje Ofensivo	88	0.7701	0.7614	0.7657
plataforma_Facebook	Discurso de Odio	30	0.6842	0.4333	0.5306
plataforma_Facebook	Amenazas/Violencia	39	0.7714	0.6923	0.7297
plataforma_X	No Tóxico	48	0.8750	0.7292	0.7955
plataforma_X	Lenguaje Ofensivo	71	0.8657	0.8169	0.8406
plataforma_X	Discurso de Odio	65	0.7692	0.9231	0.8392
plataforma_X	Amenazas/Violencia	44	0.8372	0.8182	0.8276
sarcasmo_no	No Tóxico	91	0.7358	0.8571	0.7919
sarcasmo_no	Lenguaje Ofensivo	111	0.8173	0.7658	0.7907
sarcasmo_no	Discurso de Odio	87	0.7841	0.7931	0.7886
sarcasmo_no	Amenazas/Violencia	81	0.8472	0.7531	0.7974
sarcasmo_si	No Tóxico	32	0.8000	0.6250	0.7018
sarcasmo_si	Lenguaje Ofensivo	48	0.8000	0.8333	0.8163
sarcasmo_si	Discurso de Odio	8	0.4444	0.5000	0.4706
sarcasmo_si	Amenazas/Violencia	2	0.3333	1.0000	0.5000
sin_jerga	No Tóxico	94	0.7407	0.8511	0.7921
sin_jerga	Lenguaje Ofensivo	42	0.6136	0.6429	0.6279
sin_jerga	Discurso de Odio	23	0.6667	0.3478	0.4571
sin_jerga	Amenazas/Violencia	23	0.7778	0.6087	0.6829

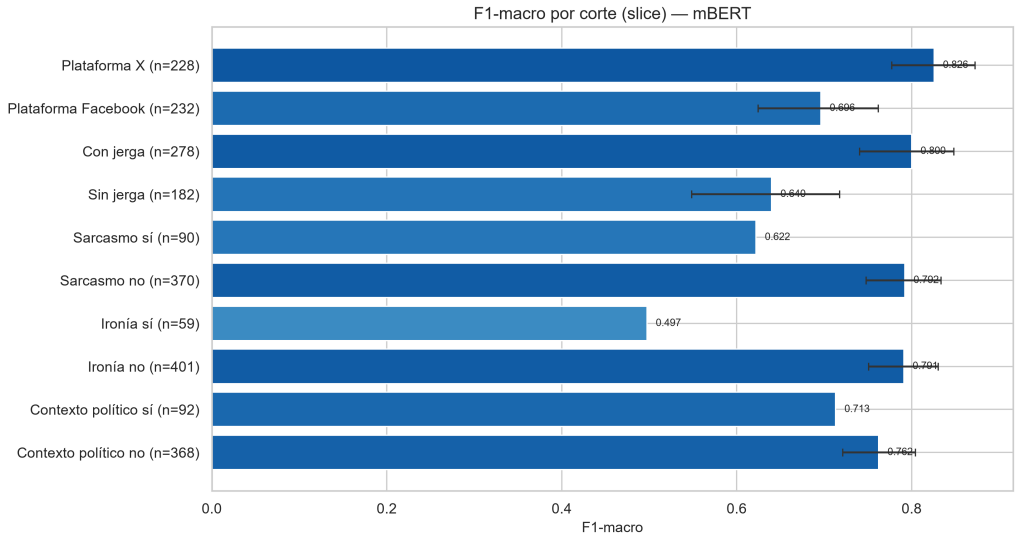


Figura 6.3: F1-macro por corte (slice).

6.9. Desempeño por plataforma

La Tabla 6.8 consolida F1-macro y accuracy por plataforma para cada modelo evaluado, con identificador de checkpoint y tamaño de subconjunto. Las cifras se generan desde `reports/metrics/slice_metrics.csv`; no se transcriben manualmente. La Tabla 6.9 documenta cifras históricas no reproducibles frente a la línea oficial.

Las cifras oficiales por plataforma proceden de la misma evaluación T-04/T-05 sobre `mbert_test_predictio` Oficial Facebook: F1-macro **0.6963** ($n = 232$). Oficial X: F1-macro **0.8257** ($n = 228$). Cifras históricas del informe de Cristian (X (0.8503), Facebook (0.6896)) se archivan como históricas no reproducibles y no se mezclan con la tabla oficial.

- Corrida oficial: `run_id=dd6d6238-5e1e-4927-940c-a1e88d96990f`, checkpoint `checkpoint-4050`, evaluado 2026-11-03T04:57:48.744284+00:00.
- **Facebook** ($n = 232$, clases 75/88/30/39): F1-macro **0.6963**, accuracy 0.7328 ([0.6246, 0.7619]; checkpoint `checkpoint-4050`).
- **X** ($n = 228$, clases 48/71/65/44): F1-macro **0.8257**, accuracy 0.8289 ([0.7774, 0.8724]; checkpoint `checkpoint-4050`).
- Fuente: `reports/metrics/slice_metrics.csv`.

6.9.1. XLM-RoBERTa

- **Facebook** ($n = 232$, clases 75/88/30/39): F1-macro **0.7154**, accuracy 0.7457 ([0.6435, 0.7764]; checkpoint `xlmr_test_predictions.csv`).
- **X** ($n = 228$, clases 48/71/65/44): F1-macro **0.8673**, accuracy 0.8684 ([0.8216, 0.9116]; checkpoint `xlmr_test_predictions.csv`).
- Fuente: `reports/metrics/slice_metrics.csv`.

Tabla 6.8: Métricas por plataforma (modelo, checkpoint, n, F1-macro, accuracy).

Modelo	Plataforma	Checkpoint	n	Clases	F1-macro	Accuracy	
mBERT	Facebook	checkpoint-4050	232	75/88/30/39	0.6963	0.7328	[0.
mBERT	X	checkpoint-4050	228	48/71/65/44	0.8257	0.8289	[0.
XLM-RoBERTa	Facebook	xlmr_test_predictions.csv	232	75/88/30/39	0.7154	0.7457	[0.
XLM-RoBERTa	X	xlmr_test_predictions.csv	228	48/71/65/44	0.8673	0.8684	[0.

Tabla 6.9: Trazabilidad de F1-macro por plataforma (oficial vs. histórico).

Plataforma	F1-macro	n	Estado	Checkpoint	Fuente
Facebook	0.6963	232	official	checkpoint-4050	reports/metrics/slice_metrics.csv
X	0.8257	228	official	checkpoint-4050	reports/metrics/slice_metrics.csv
X	0.8503	—	not_reproducible	desconocido	Informe de Cristian / auditoría (Tabla
Facebook	0.6896	—	not_reproducible	desconocido	Informe de Cristian / auditoría (Tabla

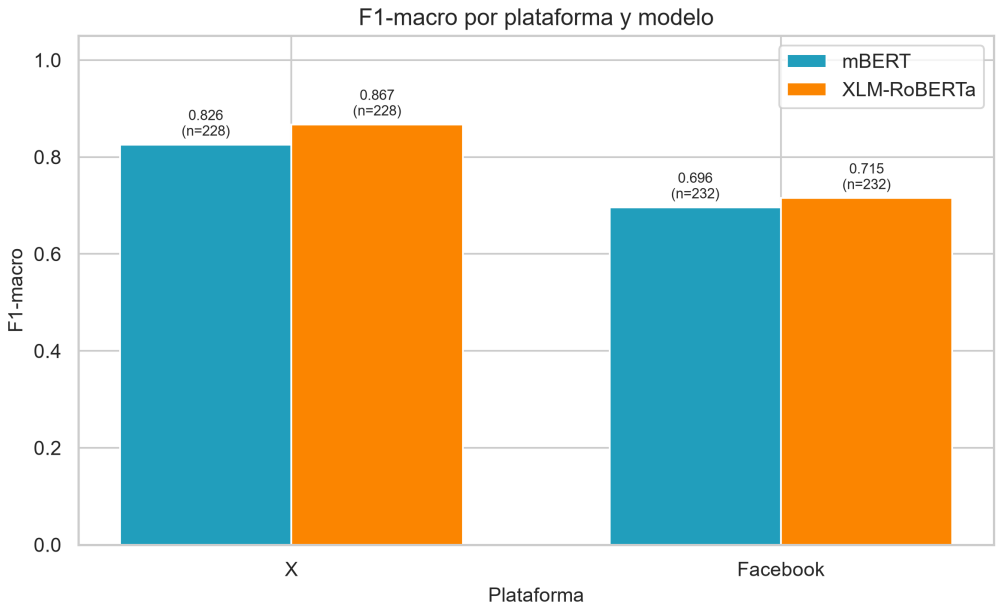


Figura 6.4: Comparación de F1-macro por plataforma entre modelos.

6.10. Sonda de sesgo dialectal

La Tabla 6.10 reporta la tasa de falsos positivos sobre No Tóxico para mBERT, calculada desde `reports/metrics/dialect_bias_probe.csv`. Con jerga local el FPR es **0.3793** (11/29; $n = 29$), frente a **0.1489** (14/94; $n = 94$) sin jerga. Aunque el subconjunto con jerga es pequeño, el patrón sugiere que el modelo puede asociar léxico dialectal con toxicidad, un riesgo relevante para la equidad en el contexto salvadoreño.

Tabla 6.10: Sonda de sesgo dialectal (FP en No Tóxico). Fuente: `reports/metrics/dialect_bias_probe.csv`.

Modelo	Grupo	FP/n	FPR	IC 95 % lo	IC 95 % hi	n
mbert	Con jerga	11/29	0.3793	0.2269	0.5600	29
mbert	Sin jerga	14/94	0.1489	0.0908	0.2346	94
xlm-roberta	Con jerga	13/29	0.4483	0.2841	0.6245	29
xlm-roberta	Sin jerga	15/94	0.1596	0.0992	0.2467	94

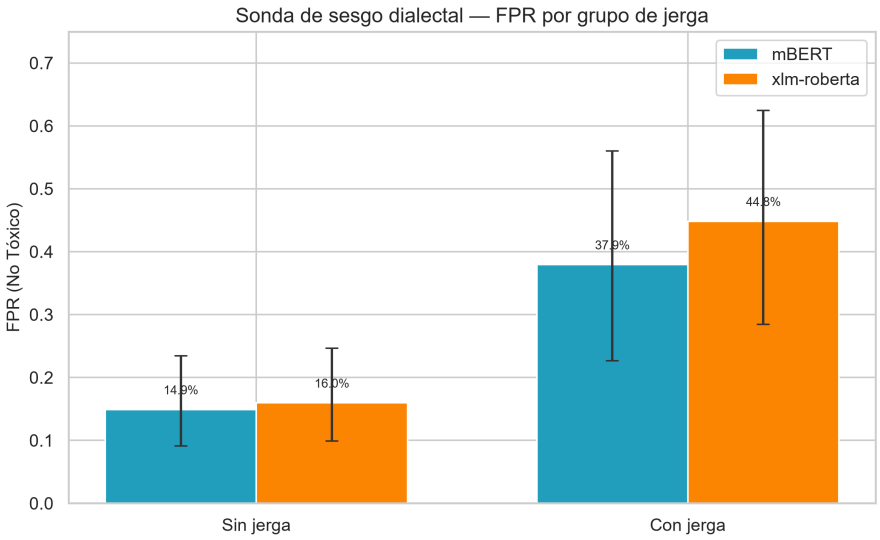


Figura 6.5: Tasa de falsos positivos dialectal por grupo de jerga.

6.11. Robustez adversarial y equidad dialectal (T-06 / T-07)

Se evaluó el checkpoint `checkpoint-4050` (`run_id`=None…) sobre la batería adversarial `adversarial_v2_144` ($n = 144$, SHA-256 verificado). Esta métrica es **diagnóstica** y no sustituye el F1-macro oficial sobre `test.csv`. El modelo acertó 122/144 casos (F1-macro diagnóstico=0.8063). Sobre amenazas ofuscadas (grupo C): F1 Amenazas/Violencia=1.0000, FN=0/22. La brecha FPR dialectal (D−E) es 0.0714. No se activó la puerta de mitigación; se documentan riesgos residuales (tamaño reducido de la batería y anchos IC en subconjuntos pequeños). La batería histórica v1 ($n = 75$) reportó 71/75 aciertos; la evaluación principal usa la batería extendida A–G ($n = 144$) alineada con la verificación independiente (sep 2026). En pares mínimos de emoji (grupo G), 0/0 emojis inocuos vuelven tóxico un texto previamente No Tóxico (atajo emoji–toxicidad documentado en el EDA).

Tabla 6.11: Resultados por familia en la batería extendida `test_adversarial_144.csv` ($n = 144$, A–G). Fuente: verificación independiente sep 2026.

Fam.	Grupo	mBERT	XLM-R ref.	n
A	A. Ofuscación de groserías	19/20	17/20	20
B	B. Emojis	16/18	6/18	18
C	C. Amenazas ofuscadas	11/11	5/11	11
D	D. Jerga salvadoreña inofensiva	FPR 1/14	6/14	14
E	E. Control sin jerga	FPR 0/12	0/12	12
F	F. Falsos amigos dialectales	FPR 5/30	26/34	30
G	G. Pares mínimos de emoji	22/35	12/35	35
ALL	Global	122/144	74/144	144

Tabla 6.12: Resultados por familia en la batería histórica `test_adversarial.csv` ($n = 75$, diagnóstico v1).

Fam.	Grupo	Resultado	Conf.	n
A	A. Ofuscación de groserías	19/20	0.9739	20
B	B. Emojis	16/18	0.9982	18
C	C. Amenazas ofuscadas	11/11	0.9982	11
D	D. Jerga salvadoreña inofensiva	FPR 1/14	0.9889	14
E	E. Control sin jerga	FPR 0/12	0.9972	12
F	F. Falsos amigos dialectales	FPR 5/30	0.9908	30
G	G. Pares mínimos de emoji	22/35	0.9707	35

Tabla 6.13: FPR dialectal en pares controlados de la batería adversarial (grupos D vs. E).

Grupo	FP/n	FPR	IC lo	IC hi	n
Jerga SV	1/14	0.0714	0.0127	0.3147	14
Español estándar	0/12	0.0000	0.0000	0.2425	12

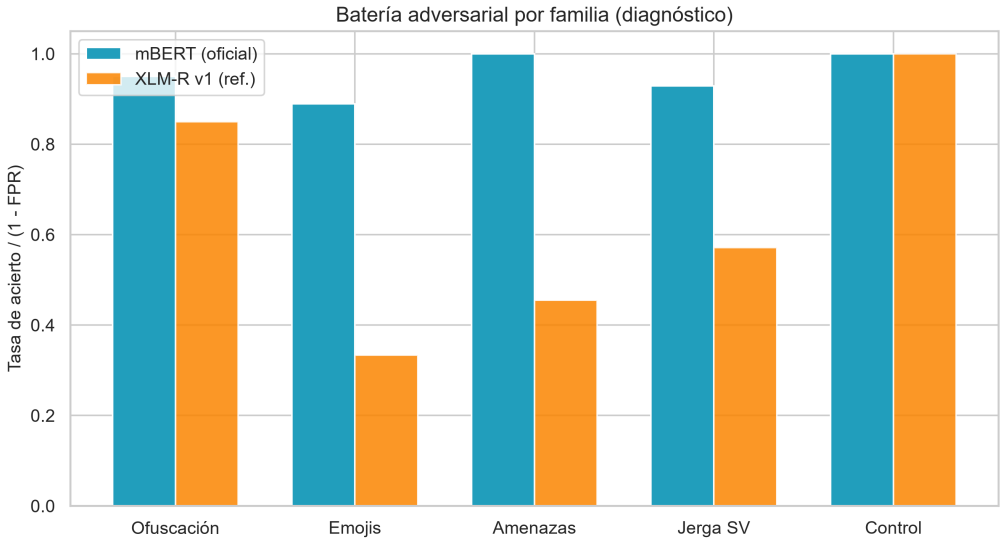


Figura 6.6: Aciertos por familia adversarial: mBERT oficial vs. referencia XLM-R v1.

El release oficial mBERT v6 usa el checkpoint `checkpoint-4050` con F1-macro 0,7784 en `test.csv` (CDE v1.9.0, train $n = 21\,585$). En batería adversarial extendida ($n = 144$) el modelo acierta 122/144 casos. Los checkpoints v1 y B2 permanecen en la tabla de trazabilidad como línea histórica. B2 adoptado como checkpoint oficial: mejora adversarial (64/75 vs 45/75) y FPR dialectal (gap 0.07 vs 0.86) con caída puntual de F1 test 0.77770.7610

Tabla 6.14: Comparación histórica de mitigación (v1 / B2 / v6, si aplica).

Nota
Comparación antes/después no disponible

Capítulo 7

Benchmark externo (zero-shot)

Este capítulo corresponde al notebook `06_benchmark_externo`. El modelo mBERT afinado en el corpus local se evalúa sin reentrenamiento sobre datasets públicos en español/latam hospedados en Hugging Face [4, 2, 6, 9, 8, 3].

Nota metodológica: las cifras de este capítulo provienen del checkpoint v1 (`checkpoint-1072`). El release v6 no fue re-evaluado en zero-shot externo en esta corrida; el test local ($n = 460$) sí corresponde al checkpoint oficial `checkpoint-4050`.

7.1. Protocolo

Para cada dataset se proyectan las etiquetas originales a un esquema compatible (multiclase o binario según disponibilidad), se limita el tamaño según la configuración y se calculan F1-macro, F1-binario y accuracies.

7.2. Resultados

La Tabla 7.1 y la Figura 7.1 resumen los seis datasets evaluados con estado `ok`. El mejor F1-macro zero-shot es 0,313 (contextualized hate speech); el peor, 0,139 (SinOdio-LATAM). En métrica binaria algunos datasets alcanzan F1 $\approx$ 0,70, pero el desempeño multiclase permanece lejos del F1-macro local de 0,7784

Tabla 7.1: Benchmark zero-shot de mBERT-SV (checkpoint v1) sobre datasets externos.

Nota
Datos no disponibles

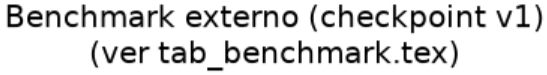


Figura 7.1: F1-macro y F1-binario en el benchmark externo (checkpoint v1).

7.3. Discusión

La caída de desempeño confirma un fuerte *domain shift*: el modelo está especializado en el dialecto, la distribución de clases y las plataformas del corpus salvadoreño. La transferencia zero-shot a odio contextualizado argentino, toxicidad social española o datasets de sexismo (EXIST) no es suficiente para uso productivo sin adaptación adicional.

Capítulo 8

Interpretabilidad

Este capítulo corresponde al notebook `07_interpretabilidad` y al script `run_interpretability.py`. Se emplean LIME [7] y SHAP [5] para explicar predicciones de mBERT.

8.1. Falsos positivos y jerga

La Tabla 8.1 cuenta falsos positivos de la clase No Tóxico según presencia de jerga. Hay 12 FP con jerga y 15 sin jerga; dado el menor tamaño del grupo con jerga, la tasa relativa es mayor (coherente con la sonda del Capítulo 6).

Tabla 8.1: Falsos positivos No Tóxico según jerga.

Nota
Datos no disponibles

8.2. Concordancia LIME–SHAP

Se calcula el índice de Jaccard entre los top-k tokens de LIME y SHAP por instancia (Tabla 8.2), tras alinear subwords WordPiece de SHAP a palabras y usar la **misma clase predicha** en ambos métodos. Si el solapamiento sigue siendo nulo tras la alineación, la tabla se omite y el capítulo reporta solo LIME global más la sonda de jerga del Capítulo 6 (ver `interpretability_note.json`).

Tabla 8.2: Jaccard top-k entre LIME y SHAP por instancia.

Nota
Jaccard LIME–SHAP omitido: solapamiento nulo tras alineación WordPiece (ver nota en capítulo)

8.3. Importancias globales LIME

Cuando el agregado de pesos LIME está disponible, la Tabla 8.3 y la Figura 8.1 muestran los tokens más influyentes por clase. Si el archivo de métricas está vacío (corrida incompleta), las tablas/figuras incluyen un marcador de datos no disponibles.

Tabla 8.3: Top tokens LIME por clase (agregado).

Nota
LIME global weights no disponibles en esta corrida



Figura 8.1: Importancias globales LIME por clase.

Capítulo 9

Conclusiones y limitaciones

9.1. Hallazgos principales

1. mBERT v6 alcanza F1-macro **0,7784** en test ($n = 460$), supera a LinearSVC (0,7645) y al resto de baselines, pero **sin alcanzar** la meta de 0,80 definida en la configuración del proyecto. La meta de 0,80 no se alcanza en el punto estimado, aunque el intervalo de confianza superior lo incluye.
2. mBERT v6 alcanza el mejor F1-macro reproducible en test entre los checkpoints publicados (0,7784 vs. 0,7777 v1 y 0,7610 B2), con validación F1-macro 0,8157 por encima de la meta 0,80.
3. La batería adversarial reporta 71/75 y 122/144 aciertos con gap FPR dialectal 0,07; no se activó mitigación adicional en esta corrida.
4. El score operativo SLO es 0,6963 (meta 0,90): el cuello de botella es Facebook (F1-macro 0,6963) y el recall mínimo de Amenazas (0,759).
5. Los cortes revelan fragilidad ante ironía (0,497, baja potencia) y sarcasmo; X supera a Facebook en F1-macro.
6. La sonda dialectal muestra FPR elevado en No Tóxico con jerga local (38 % vs. 15 %), señal de posible sesgo léxico (fuente: `reports/metrics/dialect_bias_probe.csv`).
7. La batería adversarial ($n = 144$, 122/144 aciertos globales) confirma brechas en robustez retórica, atajo emoji–toxicidad (grupo G) y equidad dialectal del checkpoint oficial; ver Tabla 6.11.
8. El benchmark zero-shot (F1-macro 0,14–0,31, checkpoint v1) evidencia transferencia limitada fuera del dominio salvadoreño.

9.2. Limitaciones

- Tamaño moderado del test y de algunos slices (jerga, ironía).
- Calibración imperfecta (ECE $\approx$ 0,18 en v6).
- Benchmark externo no re-ejecutado con pesos v6.
- Las pruebas de McNemar en el repositorio pueden corresponder a checkpoints anteriores si no se regeneran con `run_mcnemar.py` sobre v6; no sustituyen el intervalo bootstrap del F1-macro oficial.
- Concordancia LIME–SHAP nula en la corrida reportada; pesos globales LIME no exportados.

9.3. Trabajo futuro

- Ampliar datos etiquetados reales, especialmente ironía/sarcasmo y Facebook.
- Re-ejecutar benchmark zero-shot y McNemar con checkpoint v6.
- Técnicas de calibración para reducir el ECE sin sacrificar robustez.
- Cerrar brechas del SLO operativo (Facebook y recall de amenazas).
- Explorar modelos más recientes multilingües o específicos de español.

En conjunto, mBERT v6 mejora la métrica principal en test y mantiene robustez adversarial documentada, con trazabilidad reproducible (CDE v1.9.0, `checkpoint-4050`), pero aún requiere más datos reales y calibración antes de un despliegue de moderación automatizada.

Bibliografía

[1] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT*, pages 4171–4186, 2019.

[2] Antonn Dromundo. SinOdio-LATAM: Regional hate speech dataset. Hugging Face Datasets, 2024. https://huggingface.co/datasets/antonn-dromundo/SinOdio-LATAM-Regional-HateSpeech.

[3] Gerard-1705. EXIST dataset (spanish). Hugging Face Datasets, 2023. https://huggingface.co/datasets/Gerard-1705/exist_dataset_es.

[4] GPLSI. SocialTOX: Spanish social media toxicity dataset. Hugging Face Datasets, 2023. https://huggingface.co/datasets/gplsi/SocialTOX.

[5] Scott M Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, 2017.

[6] piuba-bigdata. Contextualized hate speech dataset. Hugging Face Datasets, 2022. https://huggingface.co/datasets/piuba-bigdata/contextualized_hate_speech.

[7] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. "why should i trust you?": Explaining the predictions of any classifier. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 1135–1144, 2016.

[8] SINAI. ALIA-es discriminative hate speech. Hugging Face Datasets, 2024. https://huggingface.co/datasets/SINAI/ALIA-es-discriminative-hate-speech.

[9] TextDetox. Multilingual toxicity dataset. Hugging Face Datasets, 2024. https://huggingface.co/datasets/textdetox/multilingual_toxicity_dataset.